

实验一 熟悉大数据实验平台

实验目的

- 熟悉 BDAP 平台的基本操作，包括数据加载、工作流的创建与运行，以及常见组件的使用。旨在了解工作流的整体流程。

实验内容

第一步：加载数据

- 使用 BDAP 平台的数据源组件加载台风数据集 (Asia_storm.csv)。
- 数据路径：/public/Experiment_1/Asia_storm.csv。
- 分隔符设置为逗号，文件格式为 CSV。

第二步：列投影

- 使用投影组件，选择 ADV_DATE（台风日期）和 SPEED（风速）列，提取时间与风速的对应关系。


第三步：数据排序

- 使用排序组件，对 ADV_DATE 列进行升序排列（从早到晚）。

第四步：数据可视化

- 使用可视化组件绘制折线图，展示台风风速随时间变化的趋势。

实验步骤



实验结果




图 1-1 台风风速随时间变化的趋势

实验总结

- 通过本次实验，熟悉了 BDAP 平台的操作流程，理解了工作流的概念和数据可视化的重要性。

实验二 常见的数据预处理实验

实验目的

- 学习并掌握常见的数据预处理操作，包括分组计算、排序、数据可视化等方法，理解数据预处理在数据分析中的重要性。

实验内容

第一部分：2024 年全国空气质量数据集 (air_quality.csv)


- 步骤一：加载数据
 - 使用加载数据组件，选择文件路径/public/Experiment_2/air_quality.csv，文件格式为 CSV，分隔符为逗号。
- 步骤二：数据分组 (GroupBy)
 - 使用 GroupBy 组件，以 hour 字段为聚集字段，计算 AQI 的平均值，命名为 avg_h。
 - 再以 date 字段为聚集字段，计算每天的 AQI 平均值，命名为 avg_d。
- 步骤三：数据排序
 - 对 hour 列进行升序排序，按时间点展示 AQI 的变化趋势。
 - 对 date 列进行升序排序，按日期展示 AQI 的日均值变化。
- 步骤四：数据可视化
 - 使用折线图组件，分别展示每小时和每日的 AQI 变化趋势。

第二部分：杭州亚运会运动员名单数据集 (HZ_game.csv)

- 步骤一：加载数据
 - 使用加载数据组件，选择文件路径/public/Experiment_2/HZ_game.csv，文件格式为 CSV。
- 步骤二：字符串切割
 - 使用计算生成列组件，提取每个运动员姓名的第一个字符(姓氏)，命名为 familyName。
- 步骤三：分组统计 (GroupBy)
 - 以 familyName 为聚集字段，使用 GroupBy 组件，统计各个姓氏的出现次数，命名为 familyCount。

- 步骤四：排序
- 对 familyCount 进行降序排序，找出最常见的姓氏。
- 步骤五：数据可视化
- 使用柱状图展示不同姓氏的出现次数

实验步骤



实验结果




图 2-1 每小时 AQI 变化趋势




图 2-2 每日的 AQI 变化趋势

选择展示的行数

[下载结果](#)

family_name	family_name_count
王	84
张	58
李	56
陈	47
刘	45
杨	24
黄	24

图 2-3 不同姓氏的出现次数

实验总结

- 本实验通过数据预处理操作，掌握了分组计算和排序的常见方法，并理解了数据可视化在数据分析中的重要性。
- 数据预处理是分析的关键环节，可以显著提高数据的利用价值，有助于发现数据中的规律和异常。

实验三 决策树分类实验

实验目的

- 学习使用决策树算法进行分类任务的基本原理和方法，掌握决策树的训练、验证和测试过程，了解如何利用机器学习算法进行数据分类。
- 通过对鸢尾花数据集的分类，理解决策树的构造和分类效果。

实验内容

步骤一：加载数据

- 使用数据源组件加载鸢尾花数据集 (Iris.csv)。
- 数据路径为/public/Experiment_3/Iris.csv，文件格式为 CSV，不包含表头，分隔符为逗号。

步骤二：训练决策树模型

- 拖动决策树组件到工作流中，设置相关参数：
 - 训练字段：选择鸢尾花的四个特征（花萼长度、花萼宽度、花瓣长度、花瓣宽度）。
 - 标签字段：选择鸢尾花的种类。
 - 信息增益的选择标准为基尼系数。
 - 设置最大树深度和最小信息增益等参数，以避免过拟合。
- 将模型保存到私有文件目录下的新建文件夹中，用于后续验证和测试。

步骤三：模型验证

- 使用验证数据集进行模型验证，将训练好的模型加载到验证组件中，查看预测结果。
- 验证结果包括每个样本的预测类别和真实类别的比较。

步骤四：测试模型


- 对测试数据进行预测，将结果与真实类别对比，计算预测准确率。
- 使用多分类评估器组件评估模型的性能，计算准确率 (Accuracy)。

- 准确率计算公式： $\text{Accuracy} = \text{分类正确数} / \text{样本总数}$ 。

步骤五：可视化决策树

- 使用决策树的可视化工具展示生成的树结构，解释每个节点的含义（如划分依据、条件等）。

实验步骤



实验结果

选择展示的行数

下载结果

_c0	_c1	_c2	_c3	_c4	indexed_c4	prediction	predictedLabel
5.1	3.5	1.4	0.2	Iris-setosa	0	0	Iris-setosa
4.9	3	1.4	0.2	Iris-setosa	0	0	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa	0	0	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa	0	0	Iris-setosa
5	3.6	1.4	0.2	Iris-setosa	0	0	Iris-setosa
5.4	3.9	1.7	0.4	Iris-setosa	0	0	Iris-setosa
4.6	3.4	1.4	0.3	Iris-setosa	0	0	Iris-setosa

图 3-1 部分预测结果

metric

图 3-2 分类模型准确率

实验总结

- 通过本次实验，掌握了决策树算法的基本原理和实现过程，理解了如何通过选择最佳特征进行分类。
- 学会了在 BDAP 平台上训练和评估机器学习模型的具体操作步骤，了解了验证集在防止模型过拟合中的作用。
- 决策树的可解释性使其在分类任务中具有优势，但在处理复杂数据时容易产生过拟合，需要进行剪枝等处理。

实验四 K-Means 聚类实验

实验目的

- 掌握 K-Means 聚类算法的原理和应用，了解无监督学习方法如何将数据分组。
- 使用 K-Means 算法对新能源汽车数据进行聚类分析，根据座椅数量和价格对汽车进行分组。

实验内容

步骤一：加载数据

- 使用 BDAP 平台的数据源组件加载新能源汽车数据集 (NewEnergyCar.csv)。
- 数据路径为/public/Experiment_4/NewEnergyCar.csv，文件格式为 CSV，分隔符为逗号。

步骤二：数据预处理

- 使用“填充/删除空值”组件处理缺失数据，选择“填充”模式，空白区域用列的平均值填充。
- 使用列投影组件选择所需的特征列：Seats（座椅数量）和 PriceEuro（价格）。

步骤三：K-Means 聚类


- 拖动 K-Means 组件到工作流中，设置聚类参数：
 - 聚类簇数（K）设定为 5，即将汽车分为 5 类。
 - 最大迭代次数设定为 300，收敛阈值设定为 0.001，表示在中心点变化小于 0.001 时停止迭代。
 - 训练字段选择 Seats 和 PriceEuro，标签列选择 Model（汽车型号）。
- 运行 K-Means 算法对数据进行聚类。

步骤四：数据可视化

- 使用散点图组件展示聚类结果，以 Seats 为 X 轴，PriceEuro 为 Y 轴，不同颜色表示不同的聚类类别。

- 可视化结果用于分析各类新能源汽车在座椅数量 and 价格方面的特征差异。

实验步骤



实验结果

选择展示的行数 20

下载结果

Model	cluster	PriceEuro	Seats
e-Up!	2	21421	4
CITIGOe IV	2	24534	4
Mii Electric	2	20129	4
e	2	32997	4
UX 300e	0	50000	5
e Advance	2	35921	4
e-NV200 Evalia	2	33246	7

图 4-1 聚类结果




图 4-2 散点图可视化结果

实验总结

- 本次实验学习了 K-Means 聚类的原理和在实际数据中的应用，通过聚类分析能够发现数据中的内在模式。
- 通过对新能源汽车数据的聚类探索，不仅理解了聚类算法的操作步骤，还掌握了无监督学习中常见的数据分析方法。
- 数据的预处理和参数选择对聚类结果有较大影响，调节聚类簇数（K）可以更好地适应不同的分析需求。

实验五 关联规则实验

实验目的

- 学习关联规则算法的基本原理及其应用，掌握如何利用关联规则挖掘数据中的潜在关联关系。
- 通过对电影参演人员数据集的分析，发现电影演员之间的关联规则。

实验内容

步骤一：加载数据

- 使用 BDAP 平台的数据源组件加载电影参演人员数据集 (MovieCast.csv)。
- 数据路径为/public/Experiment_5/MovieCast.csv，文件格式为 CSV，分隔符为逗号。

步骤二：数据预处理

- 检查数据格式，确保数据集中包含电影名称和参演演员信息的字段。
- 使用计算生成列或投影组件，选择与关联分析相关的字段，如演员名单。


步骤三：频繁项集挖掘

- 使用关联规则组件进行频繁项集挖掘：
 - 设置最小支持度阈值（例如 0.02），表示频繁项集需要至少出现在 2% 的事务中。
 - 设置最小置信度阈值（例如 0.5），用于筛选满足条件的关联规则。
- 运行算法，生成频繁项集，并基于频繁项集生成关联规则。

步骤四：关联规则的可视化与分析

- 使用关联规则可视化组件，展示生成的关联规则，包括项集的支持度和置信度。
- 对挖掘结果进行分析，找出具有较高置信度的关联规则，如哪些演员在同一部电影中出现的概率较高。

实验步骤



实验结果

选择展示的行数 20

下载结果

Item	Support
王学兵	0.016359918200409
杜江	0.016359918200409
陆毅	0.012269938650306749
张国立	0.010224948875255624
舒淇	0.028629856850715747
张一白	0.012269938650306749
杨祐宁	0.022494887525562373

图 5-1 生成的关联规则

选择展示的行数 20

下载结果

KnownItem	RelatedItem	Lift	Confidence	Support
杨幂,谢依霖	王琳	97.8	1	0.0102249488752556...
王琳	杨幂,谢依霖	97.8	1	0.0102249488752556...
郭采洁,杨幂	陈学冬	69.85714285714286	1	0.0102249488752556...
陈学冬	郭采洁,杨幂	69.85714285714286	0.7142857142857143	0.0102249488752556...
谢依霖	王琳	61.125	0.625	0.0102249488752556...
谢依霖	杨幂,王琳	61.125	0.625	0.0102249488752556...
王琳	谢依霖	61.12499999999999	1	0.0102249488752556...

图 5-2 挖掘结果分析

实验总结

- 通过本次实验，理解了关联规则算法的核心概念（支持度和置信度），并学会在 BDAP 平台上实现关联规则挖掘。
- 关联规则能够帮助揭示数据中隐藏的关联关系，在市场分析、推荐系统等领域有广泛应用。
- 数据的选择和参数的设置对关联规则挖掘的效果有显著影响，适当的支持度和置信度阈值能够提高规则的质量。

实验六 SVM 分类算法实验

实验目的

- 学习支持向量机（SVM）分类算法的基本原理及其应用，掌握 SVM 模型的训练和预测方法。
- 使用 SVM 算法对冠状动脉疾病分类数据集进行分析，实现对疾病分类的预测。

实验内容

步骤一：加载数据

- 使用 BDAP 平台的数据源组件加载冠状动脉疾病数据集 (HeartDisease.csv)。
- 数据路径为/public/Experiment_6/HeartDisease.csv, 文件格式为 CSV, 分隔符为逗号。

步骤二：数据预处理

- 检查数据集的完整性，处理缺失值。
- 选择合适的特征字段用于分类，如年龄、血压、胆固醇水平等。
- 使用列投影组件选择分类任务所需的字段，去除不相关的特征。


步骤三：训练 SVM 模型

- 拖动 SVM 分类组件到工作流中，设置训练参数：
 - 选择核函数类型（如线性核或径向基核）。
 - 设置惩罚参数 C，控制对误分类的惩罚强度。
 - 训练字段选择健康数据的特征，标签字段选择疾病状态。
- 运行 SVM 模型训练，将模型保存到私有文件目录中，以备验证和测试使用。

步骤四：模型验证和测试

- 使用验证集或测试集对训练好的模型进行预测，比较模型的预测结果与真实标签。
- 通过多分类评估器组件计算预测准确率和混淆矩阵，评估模型的分类性能。
- 准确率计算公式： $\text{Accuracy} = \text{分类正确数} / \text{样本总数}$ 。
- 混淆矩阵可用于分析分类结果的详细情况，如真阳、假阳、真阴和假阴数量。

实验步骤



实验结果




图 6-2 模型准确率

实验总结

- 通过本次实验，学会了 SVM 分类算法的基本原理，理解了超平面、支持向量和核函数在分类中的作用。
- 熟悉了 BDAP 平台上 SVM 模型的训练和测试流程，并掌握了如何评估分类模型的性能。

数据的选择和特征工程对 SVM 模型的分类效果有显著影响，调节核函数和参数 C 可以优化模型性能。

实验七 手写数字预测实验

实验目的

- 深入应用支持向量机（SVM）分类算法的基本原理及其应用，进一步掌握 SVM 模型的训练和预测方法，了解 BDAP 在线编程平台使用。
- 实现并评估一个基于支持向量机（SVM）的手写数字分类器。通过使用 sklearn 提供的数字数据集，构建分类器，并通过模型对测试集进行预测，最终评估分类器的性能，了解其在手写数字识别中的表现。

实验内容

步骤一：数据集获取

- 数据集来源为 sklearn 中的 Digits 数据集。Digits 数据集由 8x8 像素的数字图像组成。数据集的 images 属性存储每个图像的 8x8 灰度值数组。数据集的 target 属性存储每个图像代表的数字。

步骤二：必要库的导入

- sklearn 用于训练和评估模型，matplotlib 用于分类结果的可视化。

步骤三：数据加载与预处理

- 使用 sklearn.datasets.load_digits() 加载手写数字数据集。
- 通过 digits.images.reshape() 将图像数据展平，为后续的分类任务准备输入数据。

步骤四：训练集和测试集划分

- 使用 train_test_split() 函数，将数据集按 1:1 的比例划分为训练集和测试集。训练集用于训练模型，测试集用于评估模型的分类效果。

步骤五：模型训练

- 使用支持向量机分类器 (svm.SVC) 来训练模型。通过设置合适的 gamma 参数，优化分类器的性能，训练集上的标签 (Y_train) 用于训练，图像数据 (X_train) 作为输入特征。

步骤六：可视化结果

- 使用 `matplotlib.pyplot.imshow()` 函数查看前四个预测结果，帮助直观地查看分类器的表现。

步骤六：查看混淆矩阵

- 通过 `metrics.classification_report()` 输出分类报告，评估模型的精度、召回率、F1-score 等指标。


实验步骤

```
[1]: # 导入必要的库
import matplotlib.pyplot as plt # 用于可视化
from sklearn import datasets, svm, metrics # 用于加载数据集、训练SVM模型、评估模型
from sklearn.model_selection import train_test_split # 用于划分训练集和测试集

[2]: # 加载手写数字数据集（包含图像和标签）
digits = datasets.load_digits()

# 可视化训练集中的前4个数字样本
_, axes = plt.subplots(nrows=1, ncols=4, figsize=(10, 3)) # 创建1行4列的子图
# 将前4个数字图像展示出来
for ax, image, label in zip(axes, digits.images, digits.target):
    ax.set_axis_off() # 关闭坐标轴显示
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation="nearest") # 显示数字图像，使用灰度色图
    ax.set_title("Training: %i" % label) # 设置每张图像的标题为对应的标签（数字）

# 将手写数字图像数据从8x8的二维矩阵展平成一维数组，准备训练
n_samples = len(digits.images) # 计算样本数
data = digits.images.reshape((n_samples, -1)) # 将每张8x8图像展平为64维向量
```




```
[3]: # 创建SVM分类器，指定gamma参数
clf = svm.SVC(gamma=0.001) # SVM分类器使用径向基函数(RBF)核，gamma值较小

# 按照1:1的比例划分数据集为训练集和测试集，测试集大小为50%
X_train, X_test, Y_train, Y_test = train_test_split(data, digits.target, test_size=0.5, random_state=42)
# 其中X_train, X_test分别为图像数据，Y_train, Y_test为对应的标签数据

# 用训练集对分类器进行训练
clf.fit(X_train, Y_train) # 训练SVM分类器，使用训练数据X_train和对应标签Y_train

# 在测试集上进行预测
predicted = clf.predict(X_test) # 用训练好的模型预测测试集数据X_test

[4]: # 可视化测试集中的预测结果
_, axes = plt.subplots(nrows=1, ncols=4, figsize=(10, 3)) # 创建新的子图用于显示预测结果
for ax, image, prediction in zip(axes, X_test, predicted):
    ax.set_axis_off() # 关闭坐标轴显示
    image = image.reshape(8, 8) # 将展平后的测试样本重新reshape为8x8的图像格式
    ax.imshow(image, cmap=plt.cm.gray_r, interpolation="nearest") # 显示预测结果的图像
    ax.set_title(f"Prediction: {prediction}") # 设置标题为预测的数字标签
```



```
[5]: # 输出分类报告, 评估模型在测试集上的表现
print(
    f"Classification report for classifier {clf}:\n" # 输出模型类型
    f"{metrics.classification_report(Y_test, predicted)}\n" # 输出分类报告, 包括准确率、召回率、F1得分等指标
)
```

实验结果

Classification report for classifier SVC(gamma=0.001):					
	precision	recall	f1-score	support	
0	0.99	1.00	0.99	82	
1	1.00	1.00	1.00	89	
2	1.00	1.00	1.00	83	
3	0.99	0.97	0.98	93	
4	1.00	1.00	1.00	93	
5	0.98	0.98	0.98	99	
6	1.00	0.98	0.99	98	
7	0.97	0.99	0.98	87	
8	0.98	1.00	0.99	83	
9	0.97	0.96	0.96	92	
accuracy			0.99	899	
macro avg			0.99	899	
weighted avg			0.99	899	

图 7-1 模型混淆矩阵

对于每个类别（数字 0 到 9），精确度、召回率和 F1 得分都接近 1.00，表明 SVM 模型在识别各个类别上都表现出色，分类器的整体准确率也达到 99%。这表明我们的模型在该数据集上有非常高的准确性。

SVM 分类器对手写数字的识别准确率极高，说明模型能很好地处理该数据集。该 SVM 模型在手写数字数据集上表现出极高的鲁棒性，对大多数样本进行了准确的分类，为了减少相似数字间的误分类，可以尝试在数据增强、特征提取或模型调参上进一步优化。

实验总结

- 通过本次实验，掌握了使用 SVM 进行图像分类的基本流程。
- 进一步理解了如何通过评估指标来全面分析模型的性能。
- 加深了对机器学习模型的理解，尤其是在分类任务中的评估方法。SVM 不仅在性能上表现出色，而且通过合适的参数调优，它在实际应用中具有广泛的适应性。
- 熟悉了 BDAP 平台上在线编程模块的使用。

考虑到模型误分类的情况，我计划在后续的实验中尝试数据增强方法，如旋转、平移、缩放图像等，以增加训练集的多样性，从而提高模型对不同手写体的鲁棒性。