

目 录

第 1 章 项目简介	1
1.1 项目背景	1
1.2 项目目标	1
1.3 报告结构	2
第 2 章 系统设计	3
2.1 整体架构	3
2.2 模块划分	3
2.3 信息抽取事件模型	4
2.4 数据源说明	4
2.5 数据流程	5
第 3 章 核心算法与实现	7
3.1 L1: 正则表达式抽取	7
3.1.1 方法抽取	7
3.1.2 指标抽取	7
3.1.3 其他字段	8
3.2 L2: spaCy Matcher 规则抽取	8
3.2.1 Token 规则定义	9
3.2.2 PhraseMatcher 短语匹配	9
3.2.3 批处理优化	9
3.3 L3: NER 预训练模型抽取	10
3.3.1 实体-字段映射	10
3.3.2 领域关键词提取	10
3.4 L4: LLM 零样本抽取	10

3.4.1 提示词设计	11
3.4.2 处理流程	11
3.5 集成策略	11
3.5.1 合并策略 (Merge)	11
3.5.2 投票策略 (Vote)	12
3.6 知识图谱构建	12
3.6.1 图构建	12
3.6.2 可视化	13
第 4 章 用户界面设计及演示	14
4.1 命令行界面	14
4.2 Web 界面	15
4.2.1 结果浏览页面	15
4.2.2 方法对比页面	16
4.2.3 人工标注页面	16
4.2.4 知识图谱页面	17
第 5 章 实验结果与分析	18
5.1 数据集统计	18
5.2 各方法抽取覆盖率	18
5.3 各方法抽取能力对比	19
第 6 章 项目创新点	20
6.1 四层渐进式抽取架构	20
6.2 多方法集成与投票	20
6.3 LLM 零样本抽取	20
6.4 跨论文知识图谱	21
6.5 双匹配模式评价	21
6.6 检索效果评价闭环	21

第 7 章 环境与社会可持续发展	22
7.1 环境可持续发展考量	22
7.2 社会可持续发展考量	22
第 8 章 总结与展望	24
8.1 主要工作	24
8.2 不足与展望	24
参考文献	26
附录 A 系统使用说明	27
附录 B 项目文件结构	29

第 1 章 项目简介

1.1 项目背景

信息抽取 (Information Extraction, IE) 是从非结构化或半结构化文本中自动识别并提取特定类型信息的技术^[1]。随着学术论文数量的快速增长,研究者面临着从海量文献中系统性地获取结构化知识的挑战:一篇论文使用了哪些研究方法?基于什么数据集进行实验?取得了怎样的性能指标?这些信息散布在自然语言文本中,人工逐篇阅读和整理的效率极低。

与信息检索 (IR) 关注“找到哪些文档”不同,信息抽取关注“从文档中获取什么结构化信息”^[2]。一个有效的学术论文信息抽取系统能够自动化地将非结构化的论文文本转化为结构化的知识记录,为文献综述、研究趋势分析和知识图谱构建提供数据基础。

本项目设计并实现了一个面向英文学术论文的信息抽取系统 IEEngine。系统以 17,576 篇来自多个权威学术期刊的论文为语料,实现了从正则匹配到大语言模型的四层渐进式抽取方法,并通过集成策略融合多层结果,构建跨论文知识图谱。此外,系统基于论文 DOI 实现了多媒体信息检索功能,将文本抽取结果与论文关联的图片、视频和补充材料相链接,拓展了信息获取的维度。

1.2 项目目标

本项目的目标如下:

1. 构建一个完整的学术论文信息抽取系统,覆盖文档解析、信息抽取、结果评价和知识图谱构建的全流程;
2. 实现多个信息点的抽取,包含正则表达式匹配等多种抽取方法;
3. 调用 spaCy、NLTK 等开源 NLP 模块,并探索基于大语言模型的零样本抽取方法;
4. 提供命令行和 Web 两种用户界面,支持人工标注与 Precision/Recall/F1 评价。

1.3 报告结构

本报告共分八章：第二章介绍系统的整体设计与架构；第三章详述核心抽取算法的原理与实现；第四章描述用户界面设计；第五章展示实验结果与分析；第六章归纳项目的主要创新点；第七章讨论环境与社会可持续发展方面的考量；第八章总结全文并展望未来工作。

第2章 系统设计

2.1 整体架构

IEEngine 采用离线抽取与在线展示分离的架构。系统分为两个独立阶段：

离线阶段通过 `build_ie.py` 脚本执行，负责文档解析、多方法信息抽取、集成融合以及可选的知识图谱构建。抽取结果通过 SQLite 数据库 (`index/ie/events.db`) 持久化存储，支持分页查询与流式迭代。

在线阶段通过 `cli_ie.py` (命令行) 或 `app_ie.py` (Web UI) 启动，加载离线抽取好的结果，提供结果浏览、方法对比、人工标注和知识图谱可视化等功能。

这种分离设计使得抽取过程只需运行一次，后续的浏览、分析和标注操作无需重新处理原始文档。

2.2 模块划分

系统由以下核心模块组成：

表 2.1 系统模块划分

模块	文件	功能描述
文档解析器	<code>src/parser.py</code>	解析 .txt 文件，提取标题、期刊、摘要、正文等结构化字段，支持流式迭代解析
NLP 管线	<code>src/nlp_pipeline.py</code>	spaCy 模型的单例加载与文本处理封装，支持按需禁用管线组件
数据模型	<code>src/schema.py</code>	定义 AcademicPaperEvent 事件模型 (7 个信息点 + DOI 元数据)
结果存储	<code>src/ie_storage.py</code>	基于 SQLite 的抽取结果存储，支持分页查询、搜索与流式迭代
多媒体检索	<code>src/media.py</code>	基于 DOI 的多媒体信息检索，关联论文图片、视频及补充材料
正则抽取器	<code>src/regex_extractor.py</code>	基于正则表达式的 L1 基线抽取

续表 2.1

模块	文件	功能描述
spaCy 抽取器	src/spacy_extractor.py	基于 spaCy Matcher/PhraseMatcher 的 L2 语言学规则抽取
NER 抽取器	src/ner_extractor.py	基于 spaCy 预训练 NER 模型的 L3 命名实体抽取
LLM 抽取器	src/llm_extractor.py	基于大语言模型的 L4 零样本抽取
集成器	src/ensemble.py	多方法结果的合并/投票融合
评价系统	src/ie_evaluator.py	基于 Gold Standard 的 Precision/Recall/F1 计算
知识图谱	src/knowledge_graph.py	基于 NetworkX 的跨论文知识图谱构建与 pyvis 可视化

2.3 信息抽取事件模型

系统定义了 AcademicPaperEvent 作为核心数据模型，每篇论文对应一个事件实例，包含 doc_id、title、doi 等元数据字段和以下 7 个信息点：

表 2.2 AcademicPaperEvent 事件模型的 7 个信息点

序号	字段名	含义	示例
1	methods	研究方法/算法	如 “random forest”、“BERT”、“regression analysis”
2	datasets	数据集名称	如 “MNIST”、“ImageNet”、“SQuAD”
3	metrics	评价指标（含名称、数值、上下文）	如 “accuracy: 95.3%”、“ $p < 0.05$ ”
4	domain_keywords	领域关键词	从标题和期刊名提取的学科领域标识
5	affiliations	作者机构	如 “MIT”、“University of Oxford”
6	findings	因果发现/结论	如 “X significantly increases Y”
7	study_characteristics	研究特征	包含样本量、时间范围、地理区域

该事件模型定义在 src/schema.py 中，支持 JSON 序列化/反序列化，并提供 merge() 方法用于集成策略中的去重合并。合并时对元数据字段（如 doi）取非空优先，对列表字段执行大小写不敏感去重。

2.4 数据源说明

系统使用的数据源与信息检索系统一致，包含 17,576 篇英文学术论文，总数据量约 573 MB，文件格式为纯文本（.txt）。数据来源涵盖 Scientific Reports、Nature

Communications、American Economic Review、Management Science 等多个学科领域的权威期刊。

数据通过自建爬虫从对应出版商平台获取，格式以 PDF 和 HTML (Open Access) 为主，非 Open Access 的文章仅爬取摘要部分。爬取后使用 MinerU 开源工具将 PDF/HTML 解析为结构化 .txt 格式（解析时过滤了图片和表格），每篇文档包含标题（100% 覆盖）、期刊名（100%）、DOI（100%）、摘要（100%）、发表日期（89.9%）、作者信息（85.1%）等字段。

具体的文献分布统计见表 2.3。

表 2.3 不同期刊论文数量及占比

篇数	占比	期刊名称
5222	29.7%	Scientific Reports
2801	15.9%	Humanities and Social Sciences Communications
1734	9.9%	Nature Series
1546	8.8%	Management Science
1222	7.0%	American Economic Review
859	4.9%	Review of Economic Studies
809	4.6%	Academy of Management Journal
688	3.9%	American Political Science Review
538	3.1%	Econometrica
498	2.8%	Quarterly Journal of Economics
455	2.6%	Journal of Political Economy
445	2.5%	American Sociological Review
419	2.4%	Academy of Management Review
199	1.1%	npj Urban Sustainability
122	0.7%	American Journal of Sociology
19	0.1%	Scientific Data

2.5 数据流程

系统的完整数据处理流程如下所述。

离线抽取阶段：

1. 文档解析: `parser.py` 以流式方式遍历 `data/` 目录, 逐文件提取结构化字段 (标题、期刊、DOI、摘要、正文等), 过滤无实质内容的文档 (如封面页、勘误表), 通过生成器逐步产出, 避免全量载入内存;
2. 多方法抽取: 依次运行 L1 正则抽取、L2 spaCy Matcher 抽取、L3 NER 抽取 (可选 L4 LLM 抽取), 每种方法独立产出一组 `AcademicPaperEvent`;
3. 持久化存储: 各方法抽取结果通过 `MethodEventWriter` 分批写入 SQLite 数据库 (`events.db`), 同时生成方法级统计摘要 (`MethodSummary`);
4. 集成融合: 通过合并 (`merge`) 或投票 (`vote`) 策略将多方法结果融合为统一的事件集合;
5. 知识图谱构建: 基于融合后的抽取结果构建跨论文知识图谱, 输出交互式 HTML 可视化和 GEXF 文件。

在线展示阶段:

1. 通过 `IESTorage` 从 SQLite 分页或流式加载预抽取的事件数据;
2. 提供结果浏览、搜索、方法对比和统计分析功能;
3. 基于论文 DOI 进行多媒体信息检索, 关联展示论文相关的图片、视频和补充材料;
4. 支持人工标注和自动评价 (`Precision/Recall/F1`);
5. 展示知识图谱的交互式可视化。

第3章 核心算法与实现

本系统采用四层渐进式抽取架构，从简单的正则匹配逐步升级到大语言模型零样本抽取，每一层利用不同的技术手段覆盖不同的信息点。

3.1 L1：正则表达式抽取

正则表达式 (Regular Expression) 是信息抽取的基线方法^[1]，适用于具有固定模式的文本。本系统在 `regex_extractor.py` 中实现了 `RegexExtractor`，通过 20+ 条正则规则覆盖全部 7 个信息字段。

3.1.1 方法抽取

方法抽取使用两类正则模式：动词引导模式和已知方法名匹配。

动词引导模式通过学术论文常见的方法引入句式进行捕获：

```
1 METHOD_PATTERNS = [Python  
2     r'(?:(?:we\s+)?(?:use|employ|apply|adopt|implement|develop)\s+|  
   r'(?:(?:a\s+|an\s+|the\s+)?(?:[A-Z][a-zA-Z\s\-\-]+)?(?:\s+(?:method|  
3     approach|algorithm|model|framework|technique)))',  
4     r'(?:(?:propose|introduce|present)\s+(?:a\s+|an\s+)?|  
   r'(?:(?:novel\s+|new\s+)?(?:[A-Z][a-zA-Z\s\-\-]+)?(?:\s+(?:method|  
5     approach|algorithm|model)))',  
6 ]
```

已知方法名通过预定义列表进行精确匹配，涵盖 BERT、random forest、logistic regression、SVM 等常见方法。

3.1.2 指标抽取

指标抽取识别论文中报告的定量结果：

```
1 METRIC_PATTERNS = [Python
```

```

2     r'(accuracy|precision|recall|F1[- ]?score|AUC|BLEU|ROUGE)\s*'
3     r'(?:(of|=|is|was|:)\s*(\d+\.\d*)\s*%?',
4     r'(p\s*[<=>]\s*(\d+\.\d*)',
5     r'(?:(achieved|obtained|reached)\s+(?:an?\s+)?(\d+\.\d*)\s*%'
6     r'(accuracy|precision|recall)',
7 ]

```

抽取结果被封装为 `MetricResult` 对象，包含指标名称、数值和上下文信息。

3.1.3 其他字段

- **数据集**：匹配已知数据集名称（MNIST、ImageNet 等）和句式模式（“trained on [NAME]”、“dataset [of/called] [NAME]”）；
- **机构**：匹配学术机构模式（“University of X”、“X Institute”）和已知缩写（MIT、Stanford）；
- **发现**：匹配因果关系句式（“we find that …”、“X significantly increases Y”、“results suggest that …”）；
- **研究特征**：匹配样本量模式（“N=1234”、“500 participants”）和时间范围（“from 2010 to 2020”）；
- **领域关键词**：从标题和期刊名中提取。

所有抽取结果经过去重和截断处理（如方法字段最多保留 15 个，发现字段最多保留 5 个）。

3.2 L2: spaCy Matcher 规则抽取

SpacyExtractor 利用 spaCy 的 Matcher（基于词法属性的 token 级规则匹配）和 PhraseMatcher（精确短语匹配）实现语言学感知的抽取^[3]。与纯正则不同，spaCy Matcher 能够利用词性标注（POS）、词形还原（Lemma）和依存关系（DEP）进行更精确的模式定义。

3.2.1 Token 规则定义

以方法抽取为例，METHOD_VERB 规则匹配“动词 + 可选限定词 + 名词短语”结构：

```
1 method_verb_pattern = [  
2     {"LEMMA": {"IN": ["use", "employ", "apply", "adopt",  
3         "implement"]}},  
4     {"POS": "DET", "OP": "?"},  
5     {"POS": {"IN": ["NOUN", "PROPN", "ADJ"]}, "OP": "+"},  
6 ]
```

METHOD_PROPOSE 规则类似，匹配“propose/introduce + 可选形容词 + 名词”结构。

发现抽取定义了两条规则：FINDING_THAT (“find/show/demonstrate that …”) 和 FINDING_SIGNIFICANT (“significantly/positively [VERB]”), 利用副词和动词的语法关系捕获因果陈述。

3.2.2 PhraseMatcher 短语匹配

系统预定义了 24 个已知数据集名称和 42 个已知方法名称的短语列表，通过 PhraseMatcher 进行高效的多模式匹配：

```
1 KNOWN_DATASETS = [  
2     "MNIST", "CIFAR-10", "CIFAR-100", "ImageNet", "SQuAD",  
3     "GLUE", "SuperGLUE", "CoNLL", "Penn Treebank", ...  
4 ]  
5 KNOWN_METHODS = [  
6     "random forest", "support vector machine", "logistic  
7     regression",  
8     "deep learning", "neural network", "gradient boosting", ...  
9 ]
```

3.2.3 批处理优化

SpacyExtractor 重写了 extract_batch() 方法，利用 nlp.pipe() 进行批量 spaCy 处理 (batch_size=50)，避免逐文档重复加载模型和初始化管线的开销。

该层覆盖 methods、datasets 和 findings 三个字段，与 L1 正则层形成互补。


3.3 L3: NER 预训练模型抽取

NERExtractor 利用 spaCy 的预训练命名实体识别模型 (en_core_web_sm)，将文本中识别出的命名实体映射到 IE 字段^[4,5]。

3.3.1 实体-字段映射

系统定义了实体类型到 IE 字段的映射关系：

```
1 ENTITY_FIELD_MAP = {  
2     "ORG":      "affiliations",  
3     "GPE":      "study_characteristics",  
4     "DATE":     "study_characteristics",  
5     "CARDINAL": "study_characteristics",  
6     "PERCENT":  "metrics",  
7 }
```



- ORG 类型实体经过学术机构过滤（保留包含 university、institute 等关键词的组织，排除出版商如 IEEE、ACM）映射为机构信息；
- PERCENT 类型实体转化为 MetricResult，系统提取实体的上下文句子作为指标的语境说明；
- GPE（地名）映射为研究地理区域，DATE 映射为研究时间范围。

3.3.2 领域关键词提取

除命名实体外，NER 抽取器还利用 spaCy 的名词短语 (noun chunks) 功能提取领域关键词：从标题中提取全部名词短语，从正文中提取高频名词短语，过滤停用词和过短片段后作为领域关键词。

该层覆盖 affiliations、metrics、domain_keywords 和 study_characteristics 四个字段。


3.4 L4: LLM 零样本抽取

LLMExtractor 通过调用 OpenAI 兼容接口的大语言模型（默认 gpt-4o-mini^[6]），以零样本（zero-shot）方式从论文文本中一次性抽取全部 7 个信息字段。

3.4.1 提示词设计

系统使用结构化提示词，明确指定需要抽取的字段、格式要求和约束条件：

```
1 EXTRACTION_PROMPT = """Extract the following information
   from the
2 academic paper text. Return ONLY valid JSON.
3 Fields:
4 - methods: list of research methods/algorithms
5 - datasets: list of dataset names
6 - metrics: list of {name, value, context}
7 - domain_keywords: list of domain keywords
8 - affiliations: list of institutions
9 - findings: list of key findings (< 200 chars each)
10 - study_characteristics: {sample_size, time_range, regions}
11 Rules:
12 - Only extract explicitly stated information
13 - Return empty list/dict if not found"""
```



3.4.2 处理流程

LLM 抽取的流程为：截取论文前 8000 字符 → 构建提示词 → 调用 API → 解析 JSON 响应 → 转换为 AcademicPaperEvent。对于 JSON 解析失败的情况，系统自动处理 markdown 代码块包裹并进行重试。LLM 抽取结果的置信度设为 0.9。

该方法覆盖全部 7 个字段，但由于 API 调用成本和速率限制，主要用于评估子集（50 – 100 篇），不适合全量语料处理。

3.5 集成策略

EnsembleExtractor 将多个抽取器的结果进行融合，支持两种策略：

3.5.1 合并策略（Merge）

将所有方法的抽取结果取并集，通过 `AcademicPaperEvent.merge()` 进行去重合并。对于列表字段（如 `methods`、`datasets`），执行大小写不敏感的去重；对于 `MetricResult` 字段，按名称和数值进行去重。

```
1 def _simple_merge(self, events: list[AcademicPaperEvent]):  
2     result = events[0]  
3     for event in events[1:]:  
4         result = result.merge(event) # 链式去重合并  
5     return result
```

3.5.2 投票策略 (Vote)

统计每个抽取项在各方法中的出现次数，仅保留出现次数达到阈值 (`min_votes`) 的项。投票策略能有效过滤单一方法的噪声抽取。

```
1 def _vote_strings(self, all_items, min_votes):  
2     counter = Counter()  
3     for items in all_items:  
4         for item in items:  
5             counter[item.lower().strip()] += 1  
6     return [item for item, count in counter.items()  
7             if count >= min_votes]
```

对于 `study_characteristics` 字典字段，始终采用合并策略（不进行投票），因为该字段的子项（样本量、时间范围、地区）通常只有一种方法能够抽取到。

3.6 知识图谱构建

`KnowledgeGraph` 基于 `NetworkX`^[7] 构建跨论文知识图谱，将抽取事件中的实体及其关系建模为图结构。

3.6.1 图构建

图的构建分为两步：

1. **频率统计**：遍历全部事件，统计每个实体（方法、数据集、机构、领域）的出现次数；

2. **图构建**：对每篇论文创建 paper 节点，对频率超过阈值 (`min_entity_freq`) 的实体创建对应类型的节点，并建立关系边。

节点类型和关系定义如下：

表 3.1 知识图谱节点类型与关系定义

节点类型	含义	关系/边
paper	论文	文档标题
method	研究方法	USES_METHOD (论文→方法)
dataset	数据集	EVALUATED_ON (论文→数据集)
institution	研究机构	AUTHORED_BY (论文→机构)
domain	研究领域	BELONGS_TO (论文→领域)

3.6.2 可视化

知识图谱使用 `pyvis` 库生成交互式 HTML 可视化。不同类型的节点使用不同颜色区分，节点大小与其度数（连接数）成正比。对于大型图（超过 500 个节点），系统自动按度数排序截取 Top-500 节点以保证渲染性能。可视化使用 ForceAtlas2 物理引擎进行力导向布局。

此外，知识图谱支持导出为 GEXF 格式，可导入 Gephi 等专业图分析工具进行进一步分析。

第 4 章 用户界面设计及演示

4.1 命令行界面

命令行界面 (CLI) 通过 `cli_ie.py` 提供, 包含以下 4 个子命令和交互模式:

- `show --doc-id N`: 查看指定文档的抽取结果详情;
- `search --query "..."` `--top-k N`: 按标题、方法、数据集、关键词搜索;
- `stats`: 展示各方法的抽取覆盖率统计;
- `export --format json|csv --output file`: 导出抽取结果。

```
> uv run python cli_ie.py show --doc-id 0
[Method: ensemble_merge]

=====
Doc #0: The Imperial Origins of American Policing: Militarization and Imperial
DOI:      10.1177/0096144217705523
Method: ensemble(regex+spacy+ner)
=====
Media:      3 images, 1 video
Methods:    Monkkonen, AICs and BICs, did, various, various tactical
Datasets:   squad, source
Metrics:     p< .05, p< .01., p≤ .05., p≤ .01., p≤ .001.
Keywords:    the imperial origins, american policing, militarization and imperial feedback, the early, American Jo
urnal of Sociology
Affiliations: IACP, Police Department, SMN
Finding:     local civilian policing militarized in the early 20th-century United States due to feedback from imp
Finding:     policing reforms of the early 20th century drew from that regime
Study:       regions=['America', 'Standing Rock', 'Kraska', 'Mummolo', 'France'], time_range=1900-2019
--- Detailed Metrics ---
p = < .05
Context: .26 ** .35 ** .07 -.11 -.11 .31 ** .12 .59 ** 1 * P < .05, two-tailed tests. ** P < .01. View Table
Image A
p = < .01.
Context: 1 ** .12 .59 ** 1 * P < .05, two-tailed tests. ** P < .01. View Table Image Another possible factor
is the P
p = ≤ .05.
Context: shown as coefficients with SEs in parentheses. * P ≤ .05. ** P ≤ .01. *** P ≤ .001. View Table Image
: 1 | 2
p = ≤ .01.
Context: efficients with SEs in parentheses. * P ≤ .05. ** P ≤ .01. *** P ≤ .001. View Table Image: 1 | 2 The
next mo
p = ≤ .001.
```

图 4.1 IE 命令行界面示例: 查看文档抽取结果

交互模式下进入 REPL 循环, 支持 `show <id>`、`search <query>`、`stats`、`field <name>` (字段频率分析) 和 `quit` 命令。每条抽取结果展示 DOI、方法名、数据集、指标、领域关键词、机构、发现、研究特征等全部字段, 以及基于 DOI 的多媒体资源摘要 (关联的图片、视频和补充材料数量)。

```
> uv run python cli_ie.py search --query "machine learning"
[Method: ensemble_merge] Found 2 matches for 'machine learning'

=====
Doc #253: Understanding Delegation Through Machine Learning: A Method and Applic
DOI: 10.1017/S0003055419000522
Method: ensemble(regex+spacy+ner)

=====
Media: 2 images, 2 videos, 1 supplementary
Methods: content analysis, machine, EU directives
Metrics: percentage=only 10%
Keywords: understanding delegation through machine learning, method and application, the european union, American Political Science Review, Delegation
Study: time_range=1958-2017

=====
Doc #491: Relaxing Assumptions, Improving Inference: Integrating Machine Learnin
DOI: 10.1017/S0003055422001022
Method: ensemble(regex+spacy+ner)

=====
Media: 20 images, 2 videos, 1 supplementary
Methods: Linear Regression, random effects, method
Keywords: relaxing assumptions, improving inference, integrating machine learning and the linear regression, American Political Science Review, Integrating Machine Learning
```

图 4.2 IE 命令行界面示例：搜索符合条件文档并查看抽取结果

4.2 Web 界面

Web 界面基于 Streamlit 框架实现，包含以下四个页面：

4.2.1 结果浏览页面

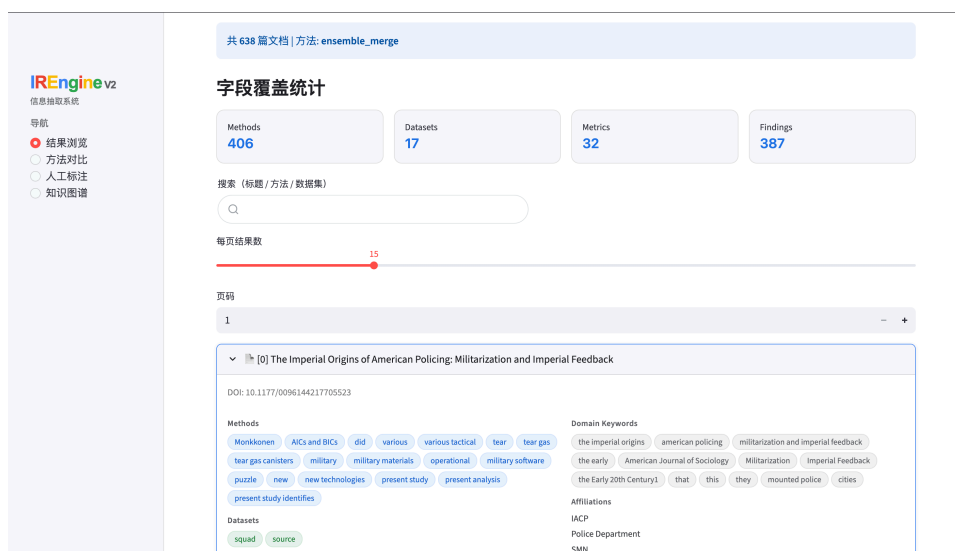


图 4.3 IE Web 界面示例：结果浏览页面

主页面提供抽取结果的浏览和搜索功能。顶部显示 4 列统计指标（总文档数、各字段非空文档数），支持按标题、方法名、数据集名搜索。每条结果以卡片形式展示，包含 DOI 标注和全部 7 个信息字段的结构化内容，字段使用两列布局排列。卡片底部通过可折叠区域展示基于 DOI 的多媒体信息检索结果，包括论文关联的图片缩略图、视频链接

和补充材料入口，实现从文本信息抽取到多媒体资源浏览的延伸。侧边栏提供方法选择器，可切换查看不同抽取方法的结果。

4.2.2 方法对比页面

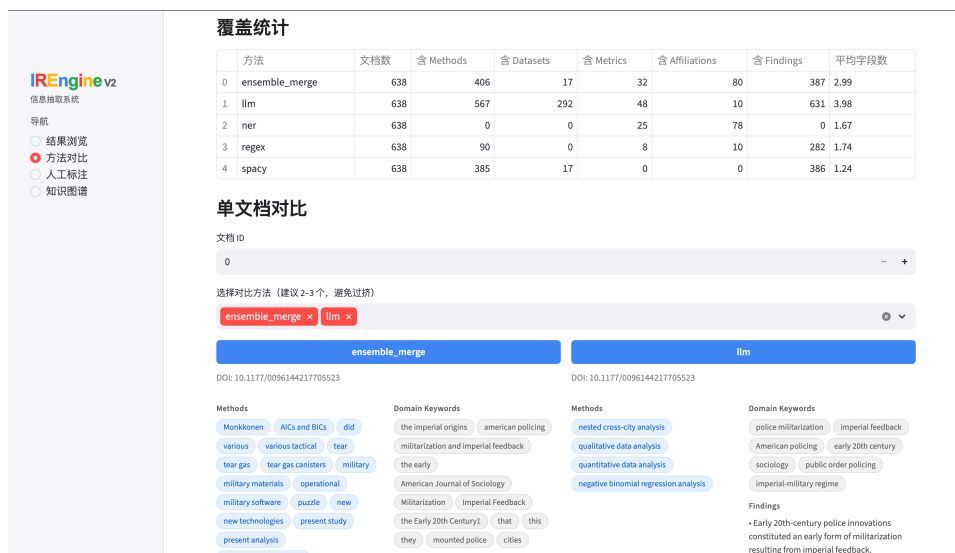


图 4.4 IE Web 界面示例：方法对比页面

对比页面展示各抽取方法的覆盖率统计表（每种方法在各字段上的非空率），支持逐文档的多方法结果并排对比。如果有 Gold Standard 标注数据，还会显示各方法的评价结果表（每字段的 Precision/Recall/F1 和 Macro/Micro F1）。

4.2.3 人工标注页面

标注页面提供人工 Gold Standard 标注界面。用户选择一个参考方法后，系统预填充该方法的抽取结果，用户可以在文本框中编辑修正每个字段的值（列表字段每行一项，study_characteristics 使用 JSON 编辑器），确认后保存为 Gold Standard 标注。



图 4.5 IE Web 界面示例：人工标注页面

4.2.4 知识图谱页面




图 4.6 IE Web 界面示例：知识图谱页面

知识图谱页面嵌入 pyvis 生成的交互式 HTML 可视化，支持按需构建图谱（可调节最小实体频率参数）。页面同时展示图的统计信息（节点数、边数、连通分量数）和各类型实体的 Top-K 排行柱状图。

第 5 章 实验结果与分析

5.1 数据集统计

系统对 17,576 篇原始论文文件进行解析后,过滤非实质性文档(封面页、勘误表等),最终有效文档数约 17,000 篇。离线抽取阶段对全量文档运行了 L1 (正则)、L2 (spaCy Matcher)、L3 (NER) 三种方法,并通过合并策略生成集成结果。

5.2 各方法抽取覆盖率

表 5.1 展示了各抽取方法在 7 个信息字段上的覆盖率(非空文档占比)。

表 5.1 各方法在不同字段上的抽取覆盖率

字段	L1 正则	L2 spaCy	L3 NER	集成(Merge)
methods	14.0%	62.0%	—	62.0%
datasets	—	3.0%	—	3.0%
metrics	8.0%	—	5.0%	7.0%
domain_keywords	100%	—	100%	100%
affiliations	—	—	10.0%	10.0%
findings	40.0%	50.0%	—	50.0%
study_characteristics	10.0%	—	47.0%	49.0%

从表 5.1 可以得出以下结论:

各层方法具有明显的互补性。L1 正则抽取在 domain_keywords 上达到 100% 覆盖率(因为标题和期刊名始终存在),但在 methods 上仅 14%。L2 spaCy Matcher 在 methods (62%) 和 findings (50%) 上表现显著优于 L1,得益于其利用词性标注和依存关系进行更精确的方法名识别。L3 NER 在 study_characteristics (47%) 和 affiliations (10%) 上贡献了独特信息,这些字段依赖于地名(GPE)和机构(ORG)等命名实体。

集成策略有效提升了覆盖率。集成结果(Merge)在所有字段上均达到了各单一方法的最高水平或更高,验证了多方法融合的有效性。

数据集抽取仍有提升空间。datasets 字段的覆盖率在所有方法中均偏低(最高 3%)，原因在于社会科学类论文较少使用标准化的公开数据集名称，大部分研究使用自建数据(如“survey data”或“administrative records”)，这些表述难以被现有的数据集名称匹配规则捕获。

5.3 各方法抽取能力对比

表 5.2 总结了四种抽取方法在各字段上的能力覆盖。

表 5.2 各方法的字段覆盖能力

字段	L1 正则	L2 spaCy	L3 NER	L4 LLM
methods	✓	✓	—	✓
datasets	✓	✓	—	✓
metrics	✓	—	✓	✓
domain_keywords	✓	—	✓	✓
affiliations	✓	—	✓	✓
findings	✓	✓	—	✓
study_characteristics	✓	—	✓	✓

L1 正则作为基线方法覆盖全部 7 个字段，但精度依赖于模式设计的质量。L2 spaCy Matcher 专注于方法、数据集和发现三个字段，利用语言学特征提升了抽取精度。L3 NER 专注于机构、指标、关键词和研究特征四个字段，利用预训练模型的实体识别能力。L4 LLM 覆盖全部字段，但受限于 API 调用成本，仅用于小规模评估。

第 6 章 项目创新点

在满足课程基本要求的基础上，本项目在算法设计、系统架构和用户体验方面做了若干额外的探索。

6.1 四层渐进式抽取架构

本系统设计了从简单到复杂的四层渐进式抽取架构：L1 正则 → L2 spaCy Matcher → L3 NER → L4 LLM。每一层利用不同技术能力覆盖不同的信息字段，层间形成互补关系。

这种分层设计的优势在于：(1) 各层独立运行，可按需选择；(2) 简单层（正则）快速且无外部依赖，复杂层（LLM）精度高但成本也高；(3) 为集成策略提供了多个信号源。

6.2 多方法集成与投票

系统实现了两种集成策略——合并（并集去重）和投票（多数表决），使用户可以在覆盖率和精度之间灵活权衡。投票策略要求一个抽取项被至少 N 种方法同时识别才予以保留，能够有效过滤单一方法的噪声。

这种集成思想借鉴了机器学习中的 Ensemble Learning 理念，将多个“弱抽取器”的结果融合为更强的抽取。

6.3 LLM 零样本抽取

利用大语言模型进行零样本信息抽取是一种新兴的技术路线^[8]。传统 IE 方法依赖于标注数据训练或手工规则设计，而 LLM 零样本方法只需通过自然语言描述抽取需求，即可在不进行任何训练的情况下完成抽取任务。

本项目的 LLM 抽取器通过精心设计的结构化提示词，一次性从论文文本中抽取全部 7 个字段的信息，并直接输出 JSON 格式的结构化结果。这种方法在覆盖度和灵活性上优于基于规则的方法，但存在 API 调用成本和响应延迟等限制。

6.4 跨论文知识图谱

系统不仅对单篇论文进行信息抽取，还将全部抽取结果整合为一个跨论文知识图谱。知识图谱以论文为中心节点，通过 USES_METHOD、EVALUATED_ON、AUTHORED_BY、BELONGS_TO 四种关系将论文与方法、数据集、机构、领域等实体连接起来。

通过知识图谱，用户可以直观地发现：哪些方法被最多的论文使用？哪些机构在特定领域最活跃？哪些数据集被跨学科使用？这些洞察超越了单篇论文抽取的价值。

6.5 双匹配模式评价

评价系统支持精确匹配（Exact Match）和部分匹配（Partial Match）两种模式。精确匹配要求抽取结果与 Gold Standard 完全一致，部分匹配则通过 token 重叠率（ $\geq 50\%$ ）进行宽松匹配。

部分匹配模式更适合信息抽取任务的评价，因为同一信息可能有多种合理的表述方式（如 “support vector machine” vs “SVM”），严格的精确匹配会低估系统的实际性能。

6.6 检索效果评价闭环

系统提供了完整的评价闭环：Web UI 的标注页面支持人工标注 Gold Standard → 评价系统自动计算 P/R/F1 → 方法对比页面展示评价结果。标注数据以 JSON 格式持久化，支持跨会话积累。

第 7 章 环境与社会可持续发展

7.1 环境可持续发展考量

系统设计中若有若干举措有助于减少资源消耗：

离线抽取与在线展示分离：信息抽取是一次性操作，抽取完成后结果持久化到 SQLite 数据库，后续的浏览、分析和标注操作无需重新处理原始文档，避免了重复的 NLP 计算。

流式解析与分页加载：文档解析采用生成器逐步产出，避免将全部文档同时载入内存；在线展示通过 SQLite 分页查询替代全量 JSON 加载，Web 端内存占用从 $O(n)$ 降至 $O(\text{页大小})$ 。

NLP 模型单例加载与按需禁用：`nlp_pipeline.py` 采用单例模式管理 spaCy 模型，多个抽取器 (L2 spaCy Matcher 和 L3 NER) 共享同一个模型实例，避免重复加载带来的内存浪费。同时支持 `disable` 参数按需禁用不需要的管线组件（如 NER 抽取器禁用 `parser`），减少不必要的计算开销。

分层抽取按需选择：用户可以根据实际需求选择只运行轻量级的 L1 正则抽取（无外部模型依赖、毫秒级响应），而不必每次都运行完整的四层管线。L4 LLM 抽取仅在需要高质量小规模评估时使用，避免了不必要的 API 调用和碳排放。

知识图谱的频率过滤：构建知识图谱时通过 `min_entity_freq` 参数过滤低频实体，只保留在多篇论文中出现的实体，既减少了图的规模和渲染开销，也提高了可视化的信息密度。

7.2 社会可持续发展考量

促进知识发现：信息抽取系统的核心价值在于将非结构化的学术文本转化为结构化的知识。本系统自动化地从 17,000+ 篇论文中提取研究方法、数据集、机构等信息，并通过知识图谱揭示跨论文的知识关联，帮助研究者更高效地进行文献调研和研究趋势分析。

开放技术栈：系统完全基于开源工具构建（Python、spaCy、NLTK、NetworkX、Streamlit 等），不依赖商业软件。除 L4 LLM 抽取器外，所有功能均可在本地完成，不涉及用户数据的外部传输。

可解释性：L1 正则和 L2 spaCy Matcher 的抽取规则完全透明，用户可以审查和理解每条抽取结果的来源。即使是 L3 NER 抽取，系统也保留了实体类型标注信息，便于结果验证。

第 8 章 总结与展望

8.1 主要工作

本项目设计并实现了 IEEngine 学术论文信息抽取系统，完成了以下工作：

1. 定义了包含 7 个信息点的 AcademicPaperEvent 事件模型，覆盖研究方法、数据集、评价指标、领域关键词、机构、发现和研究特征，并关联 DOI 元数据以支持多媒体信息检索；
2. 实现了四层渐进式抽取架构：L1 正则表达式 (20+ 条规则)、L2 spaCy Matcher (token 规则 + PhraseMatcher)、L3 NER 预训练模型、L4 LLM 零样本抽取；
3. 实现了合并与投票两种集成策略，融合多方法抽取结果；
4. 实现了基于 SQLite 的存储层 (IEStorage)，支持分页查询、全文搜索与流式迭代，替代原有全量 JSON 加载方式；
5. 基于 NetworkX 和 pyvis 构建了跨论文知识图谱，支持交互式可视化和 GEXF 导出；
6. 实现了基于 DOI 的多媒体信息检索功能，关联展示论文相关的图片、视频和补充材料，将文本信息抽取延伸至多媒体资源浏览；
7. 实现了精确匹配与部分匹配两种模式的 Precision/Recall/F1 评价系统；
8. 提供了 Streamlit Web UI (4 页面) 和 CLI (4 子命令 + 交互模式) 两种界面；
9. 在 17,576 篇跨学科学术论文上完成了全量抽取与评估。

8.2 不足与展望

受限于个人时间和资源，系统仍有以下不足：

1. **Gold Standard 标注不足**：当前人工标注数据较少，后续应标注更多文档以获取更可靠的评价指标；
2. **数据集抽取效果有限**：社会科学类论文较少使用标准化数据集名称，当前的数据集匹配规则覆盖率偏低，后续可尝试基于上下文的数据集描述识别；

3. **NER 模型通用性**：当前使用的 `en_core_web_sm` 是通用领域 NER 模型，后续可考虑使用 SciBERT 等科学领域预训练模型^[9] 以提升学术文本上的实体识别精度；
4. **关系抽取**：当前的知识图谱仅建模了论文与实体之间的关系，后续可尝试抽取实体间的直接关系（如“方法 A 优于方法 B”）以构建更丰富的知识网络。

参考文献

- [1] SARAWAGI S. Information Extraction[J]. Foundations and Trends in Databases, 2008, 1(3): 261-377.
- [2] MANNING C D, RAGHAVAN P, SCHÜTZE H. Introduction to Information Retrieval[M]. Cambridge University Press, 2008.
- [3] HONNIBAL M, MONTANI I, VAN LANDEGHEM S, et al. spaCy: Industrial-Strength Natural Language Processing in Python[C]. 2020.
- [4] LI J, SUN A, HAN J, et al. A Survey on Deep Learning for Named Entity Recognition[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(1): 50-70.
- [5] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural Architectures for Named Entity Recognition[C]//Proceedings of NAACL-HLT. 2016: 260-270.
- [6] OPENAI. GPT-4 Technical Report[J]. arXiv preprint arXiv:2303.08774, 2023.
- [7] HAGBERG A A, SCHULT D A, SWART P J. Exploring Network Structure, Dynamics, and Function using NetworkX[C]//Proceedings of the 7th Python in Science Conference. 2008: 11-15.
- [8] BROWN T, MANN B, RYDER N, et al. Language Models are Few-Shot Learners[J]. Advances in Neural Information Processing Systems, 2020, 33: 1877-1901.
- [9] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[J]. Proceedings of NAACL-HLT, 2019: 4171-4186.
- [10] BIRD S, KLEIN E, LOPER E. Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit[M]. O'Reilly Media, 2009.
- [11] PORTER M F. An Algorithm for Suffix Stripping[J]. Program, 1980, 14(3): 130-137.
- [12] SPÄRCK JONES K. A Statistical Interpretation of Term Specificity and Its Application in Retrieval[J]. Journal of Documentation, 1972, 28(1): 11-21.
- [13] MILLER G A. WordNet: A Lexical Database for English[J]. Communications of the ACM, 1995, 38(11): 39-41.
- [14] WEI X, CUI X, HOLBER N, et al. Named Entity Recognition in the Biomedical Domain: A Survey[J]. Journal of Biomedical Informatics, 2020, 107: 103442.
- [15] AUGENSTEIN I, DAS M, RIEDEL S, et al. SemEval 2017 Task 10: ScienceIE — Extracting Keyphrases and Relations from Scientific Publications[J]. Proceedings of SemEval, 2017: 546-555.
- [16] LUAN Y, HE L, OSTENDORF M, et al. Multi-Task Identification of Entities, Relations, and Coreference for Scientific Knowledge Graph Construction[C]//Proceedings of EMNLP. 2018: 3219-3232.
- [17] BAEZA-YATES R, RIBEIRO-NETO B. Modern Information Retrieval: The Concepts and Technology behind Search[M]. 2nd ed. Addison-Wesley, 2011.

附录 A 系统使用说明

A.1 环境安装

本系统使用 Python 3.11+ 开发，推荐使用 uv 包管理器进行依赖安装：

```
1 uv sync
```

 Bash

主要依赖包括：spaCy（NLP 管线、NER）、NLTK（辅助文本处理）、NetworkX（知识图谱）、pyvis（图可视化）、Streamlit（Web UI）。

A.2 离线抽取

```
1 # 运行 L1 + L2 + L3 三层抽取（默认）
2 uv run python build_ie.py --data-dir data --output-dir index/ie
3
4 # 指定抽取方法
5 uv run python build_ie.py --methods regex spacy ner
6
7 # 启用集成和知识图谱
8 uv run python build_ie.py --ensemble --knowledge-graph
9
10 # 限制文档数量（调试用）
11 uv run python build_ie.py --limit 100
```

 Bash

A.3 命令行工具

```
1 # 查看特定文档的抽取结果
2 uv run python cli_ie.py show --doc-id 0
3
4 # 搜索抽取结果
5 uv run python cli_ie.py search --query "machine learning"
6
7 # 查看抽取统计
```

 Bash

```
8  uv run python cli_ie.py stats
9
10 # 导出结果
11 uv run python cli_ie.py export --format json --output results.json
12
13 # 进入交互模式
14 uv run python cli_ie.py interactive
```

A.4 Web 界面

```
1  uv run streamlit run app_ie.py
```



附录 B 项目文件结构

1	IREngine/	
2	— app_ie.py	# Streamlit Web UI (4 页面)
3	— cli_ie.py	# 命令行工具 (4 子命令 + 交互模式)
4	— build_ie.py	# 离线抽取脚本
5	— pyproject.toml	# 项目配置与依赖
6	— src/	
7	— schema.py	# AcademicPaperEvent 事件模型
8	— parser.py	# 文档解析器 (支持流式迭代)
9	— nlp_pipeline.py	# spaCy NLP 管线 (单例加载, 按需禁用组件)
10	— base_extractor.py	# 抽取器基类
11	— regex_extractor.py	# L1 正则表达式抽取
12	— spacy_extractor.py	# L2 spaCy Matcher 规则抽取
13	— ner_extractor.py	# L3 NER 预训练模型抽取
14	— llm_extractor.py	# L4 LLM 零样本抽取
15	— ensemble.py	# 多方法集成 (合并/投票)
16	— ie_storage.py	# SQLite 结果存储 (分页、搜索、流式迭代)
17	— media.py	# DOI 关联多媒体信息检索
18	— ie_evaluator.py	# P/R/F1 评价系统
19	— knowledge_graph.py	# 知识图谱构建与可视化
20	— data/	# 原始论文数据 (17,576 篇 .txt)
21	— index/	
22	— ie/	# 抽取结果与知识图谱
23	— events.db	# SQLite 抽取结果数据库
24	— media_assets.db	# DOI 关联媒体缓存 (可选)
25	— knowledge_graph.html	
26	— tests/	# 单元测试