

摘 要

这篇论文提出 Visual AutoRegressive Modeling (VAR), 把图像自回归从传统的 raster-scan next-token prediction 改写为 coarse-to-fine next-scale prediction。作者的基本判断是: 图像没有天然的一维顺序, 将二维 token map 展平为语言式序列会削弱空间结构并拖慢推理; 更合理的顺序应当是先生成低分辨率结构, 再逐步补充高分辨率细节。论文在 ImageNet 类条件生成上报告了强于传统视觉 AR 和部分 diffusion Transformer 模型的结果, 并进一步讨论了 scaling laws 与零样本下游任务表现。本文主要围绕“为什么需要改写自回归顺序”“VAR 如何实现 next-scale prediction”“实验支持了哪些论断”三个问题展开。

关键词: 视觉自回归, 下一尺度预测, 多尺度量化, 图像生成, 扩展规律

目 录

第 1 章 论文基本信息	1
第 2 章 核心问题：为什么传统视觉 AR 不够自然	3
第 3 章 方法主线：从 next-token 到 next-scale	5
3.1 标准 AR 形式	5
3.2 VAR 的概率分解	5
3.3 多尺度 VQVAE 与两阶段训练	6
3.4 VAR Transformer	6
第 4 章 实验结果：质量、速度与扩展性	8
4.1 ImageNet 256×256 主结果	8
4.2 ImageNet 512×512 补充结果	9
4.3 Scaling laws	10
第 5 章 零样本下游任务	13
第 6 章 消融实验：主要增益来源	14
第 7 章 批判性讨论	15
7.1 强点	15
7.2 保留意见	15
第 8 章 总体评价	17

第 1 章 论文基本信息

我选择阅读的论文是 **Visual Autoregressive Modeling: Scalable Image Generation via Next-Scale Prediction**，来自 **NeurIPS 2024 Oral** 并获得 **NeurIPS 2024 Best Paper**。作者来自 Peking University 与 Bytedance Inc.。

- 论文链接: <https://arxiv.org/abs/2404.02905>
- 仓库链接: <https://github.com/FoundationVision/VAR>

总体来看，VAR 把视觉自回归的基本单位从“单个视觉 token”改成“一个尺度上的整张 token map”，用多尺度 VQVAE 提供由粗到细的 token map 序列，再用 GPT-style decoder-only Transformer 做 next-scale prediction。图 1.1 展示了论文中的 ImageNet 生成样例和零样本编辑样例，有助于把握任务形态。



图 1.1 原论文 Figure 1: Generated samples from Visual AutoRegressive (VAR) transformers trained on ImageNet.

这篇论文值得关注之处不只在 FID 数字，还在于它对“图像顺序”的重新定义。语言模型里的 next-token prediction 之所以自然，是因为文本本身有相对明确的顺序；图像

则不同，左上角 token 并不一定比右下角 token 更先验。传统视觉 AR 使用 raster order，实质上是把语言中的顺序假设迁移到图像。VAR 的出发点正是质疑这一假设。

第2章 核心问题：为什么传统视觉 AR 不够自然

传统视觉自回归的流程较为清晰：先用 VQVAE 或 VQGAN 把图像压成二维离散 token map，再按从左到右、从上到下的 raster-scan 顺序展平为一维序列，最后像语言模型一样预测下一个 token。图 2.1 对比了语言 AR、传统图像 AR 和 VAR 的三种顺序定义，是理解论文动机的关键图示。




图 2.1 原论文 Figure 2: Standard autoregressive modeling (AR) vs. proposed visual autoregressive modeling (VAR).

作者认为 raster-scan 图像 AR 至少有四个问题。其一，VQVAE 编码得到的图像特征在空间上天然有双向依赖，而一维 AR 前缀只能利用已有前缀信息。其二，这种单向前缀限制不适合需要双向上下文的任务，例如只给下半部分图像来补全上半部分。其三，二维空间局部性在展平为一维序列后被削弱，相邻像素或相邻 patch 的关系难以自然保留。其四，标准 self-attention transformer 生成 $n \times n$ latent map 时，需要 $\mathcal{O}(n^2)$ 个自回归步骤，总计算复杂度为 $\mathcal{O}(n^6)$ ；论文在 Appendix B 中给出了复杂度推导。

这一论断需要进一步区分。论文说 raster AR 违背单向依赖前提，这个表述从概率链式法则看并不是严格的数学障碍，因为任意联合分布都可以按任意顺序分解。更关键的问题在于：raster order 对图像来说并非合适的归纳偏置，它既低效，也不符合图像的层级结构。VAR 的主要意义正在这个层面上成立。

VAR 的建模直觉符合由粗到细的视觉生成过程：先形成整体轮廓和布局，再补充局部纹理与高频细节。图 2.2 把 VAR 与其他模型家族放在 ImageNet 256×256 benchmark 上比较，作者希望说明的经验现象是：当模型变大时，VAR 的生成质量指标仍然能继续改善。




图 2.2 原论文 Figure 3: Scaling behavior of different model families on ImageNet 256×256 generation benchmark.

第3章 方法主线：从 next-token 到 next-scale

3.1 标准 AR 形式

标准自回归模型处理一维离散序列 $x = (x_1, x_2, \dots, x_T)$ ，其中 $x_t \in [V]$ 。论文 Section 3.1 给出的 Equation 1 是：

$$p(x_1, x_2, \dots, x_T) = \prod_{t=1}^T p(x_t | x_1, x_2, \dots, x_{t-1}). \quad (3.1)$$

图像若采用这一形式，必须先经过 tokenizer。论文沿用 VQVAE/VQGAN 系列的基本思路：原图 im 经编码器 $\mathcal{E}$ 得到连续特征 f ，量化器 $\mathcal{Q}$ 将其映射为离散 token map q ，再通过 codebook lookup 与 decoder 重建图像。论文 Equation 5 给出的 VQVAE 训练损失包括图像重建项、特征量化项、perceptual loss 和 discriminative loss：

$$\mathcal{L} = \|im - \hat{im}\|_2 + \|f - \hat{f}\|_2 + \lambda_P \mathcal{L}_P(\hat{im}) + \lambda_G \mathcal{L}_G(\hat{im}). \quad (3.2)$$

由此可见，论文关注的是 VQVAE token 的组织 and 预测方式，而非替换 VQVAE 本身。传统方法把二维 $q \in [V]^{h \times w}$ 展平成一维序列，VAR 则试图把 token map 的尺度结构显式保留下来。

3.2 VAR 的概率分解

VAR 把图像表示为多尺度 token maps：

$$R = (r_1, r_2, \dots, r_K), \quad r_k \in [V]^{h_k \times w_k}. \quad (3.3)$$

它的联合概率分解不再以单个 token 为单位，而是以尺度为单位。论文 Equation 6 写作：

$$p(r_1, r_2, \dots, r_K) = \prod_{k=1}^K p(r_k | r_1, r_2, \dots, r_{k-1}). \quad (3.4)$$

该式给出了全文的核心形式化变化。标准 AR 预测的是“当前 token 条件于前面 token”，VAR 预测的是“当前尺度整张 token map 条件于前面所有尺度”。在第 k 步中， r_k 内部所有 $h_k \times w_k$ 个 token 的分布可以并行得到；自回归约束只发生在尺度之间，而不是同一尺度内部。因此，生成步数从 token 数量级降到尺度数量级。

3.3 多尺度 VQVAE 与两阶段训练

图 3.1 给出了 VAR 的两阶段结构。Stage 1 训练多尺度 VQ autoencoder，将图像编码为 K 个 token map $R = (r_1, r_2, \dots, r_K)$ ；Stage 2 训练 VAR Transformer，以 $([s], r_1, r_2, \dots, r_{K-1})$ 为输入，预测 $(r_1, r_2, r_3, \dots, r_K)k$ 个尺度只能访问 $r_{\leq k}$ ；推理时同一尺度的 token 并行采样。




图 3.1 原论文 Figure 4: VAR involves two separated training stages.

多尺度 VQVAE 采用残差式量化。Algorithm 1 中，编码器先得到 $f = \mathcal{E}(im)$ ，第 k 个尺度把当前残差特征插值到 (h_k, w_k) 后量化为 r_k ，再查表得到 z_k ，上采样到最高分辨率，经 φ_k 后从当前残差 f 中减去。Algorithm 2 则反过来，把每个尺度贡献累加成 $\hat{f}$ ，最后经 decoder 还原图像。

该设计对应一种由粗到细的残差分解思路：低尺度 token 尽量解释全局结构，高尺度 token 解释剩余细节。所有尺度共享 codebook Z ，词表大小在 Section 4 中给为 $V = 4096$ 。论文还说明 tokenizer 基本沿用 VQGAN 架构，只加入多尺度量化方案和 K 个额外卷积层，额外参数为 0.03M；tokenizer 在 OpenImages 上训练，空间下采样率为 $16 \times$ 。

3.4 VAR Transformer

VAR Transformer 的结构较为直接。论文采用 GPT-2/VQGAN 风格的 decoder-only Transformer, 并加入 adaptive layer normalization (AdaLN)。类条件生成时, 类别 embedding 同时作为 start token [s] 和 AdaLN 条件。作者还发现将 attention 中的 query 和 key 归一化到单位向量有助于稳定训练。

模型形状按深度 d 缩放, Section 4 给出:

$$w = 64d, \quad h = d, \quad \text{dr} = 0.1 \cdot \frac{d}{24}. \quad (3.5)$$

参数量近似为:

$$N(d) = d \cdot 4w^2 + d \cdot 8w^2 + d \cdot 6w^2 = 18dw^2 = 73728d^3. \quad (3.6)$$

值得注意的是, 作者没有引入 RoPE、SwiGLU、RMSNorm 等现代 LLM 常见组件。这一设置使论文主线较为明确: 主要增益来自 next-scale prediction 这一建模重排, 而不是复杂架构堆叠。

第 4 章 实验结果：质量、速度与扩展性

4.1 ImageNet 256×256 主结果

Table 1: **Generative model family comparison on class-conditional ImageNet 256×256 .** “↓” or “↑” indicate lower or higher values are better. Metrics include Fréchet inception distance (FID), inception score (IS), precision (Pre) and recall (rec). “#Step”: the number of model runs needed to generate an image. Wall-clock inference time relative to VAR is reported. Models with the suffix “-re” used rejection sampling. †: taken from MaskGIT [17].

Type	Model	FID↓	IS↑	Pre↑	Rec↑	#Para	#Step	Time
GAN	BigGAN [13]	6.95	224.5	0.89	0.38	112M	1	—
GAN	GigaGAN [42]	3.45	225.5	0.84	0.61	569M	1	—
GAN	StyleGan-XL [74]	2.30	265.1	0.78	0.53	166M	1	0.3 [74]
Diff.	ADM [26]	10.94	101.0	0.69	0.63	554M	250	168 [74]
Diff.	CDM [36]	4.88	158.7	—	—	—	8100	—
Diff.	LDM-4-G [70]	3.60	247.7	—	—	400M	250	—
Diff.	DiT-L/2 [63]	5.02	167.2	0.75	0.57	458M	250	31
Diff.	DiT-XL/2 [63]	2.27	278.2	0.83	0.57	675M	250	45
Diff.	L-DiT-3B [3]	2.10	304.4	0.82	0.60	3.0B	250	>45
Diff.	L-DiT-7B [3]	2.28	316.2	0.83	0.58	7.0B	250	>45
Mask.	MaskGIT [17]	6.18	182.1	0.80	0.51	227M	8	0.5 [17]
Mask.	RCG (cond.) [51]	3.49	215.5	—	—	502M	20	1.9 [51]
AR	VQVAE-2† [68]	31.11	~45	0.36	0.57	13.5B	5120	—
AR	VQGAN† [30]	18.65	80.4	0.78	0.26	227M	256	19 [17]
AR	VQGAN [30]	15.78	74.3	—	—	1.4B	256	24
AR	VQGAN-re [30]	5.20	280.3	—	—	1.4B	256	24
AR	ViTVQ [92]	4.17	175.1	—	—	1.7B	1024	>24
AR	ViTVQ-re [92]	3.04	227.4	—	—	1.7B	1024	>24
AR	RQTran. [50]	7.55	134.0	—	—	3.8B	68	21
AR	RQTran.-re [50]	3.80	323.7	—	—	3.8B	68	21
VAR	VAR- <i>d</i> 16	3.30	274.4	0.84	0.51	310M	10	0.4
VAR	VAR- <i>d</i> 20	2.57	302.6	0.83	0.56	600M	10	0.5
VAR	VAR- <i>d</i> 24	2.09	312.9	0.82	0.59	1.0B	10	0.6
VAR	VAR- <i>d</i> 30	1.92	323.1	0.82	0.59	2.0B	10	1
VAR	VAR- <i>d</i> 30-re	1.73	350.2	0.82	0.60	2.0B	10	1
	(validation data)	1.78	236.9	0.75	0.67			

图 4.1 原论文 Table 1: Generative model family comparison on class-conditional ImageNet 256×256 .

图 4.1 是论文的主要结果表，任务是 class-conditional ImageNet 256×256 generation。表中同时比较 GAN、diffusion、masked-prediction、传统 AR 和 VAR。指标包括 Fréchet

Inception Distance (FID)、Inception Score (IS)、precision、recall、参数量、生成步骤数和相对 wall-clock time。

图 4.1 中，VAR-d30-re 的 FID 为 1.73，IS 为 350.2，precision 为 0.82，recall 为 0.60，参数量为 2.0B，生成步骤数为 10，相对时间为 1。传统 AR baseline VQGAN 的 FID 为 18.65、IS 为 80.4、参数量为 227M、生成步骤为 256、相对时间为 19。这组结果表明，VAR 不只是质量更高，采样串行步数也显著减少。

与 DiT 的比较需要谨慎。图 4.1 中 DiT-XL/2 的 FID 为 2.27，IS 为 278.2，步骤数为 250，相对时间为 45；L-DiT-3B 的 FID 为 2.10，L-DiT-7B 的 FID 为 2.28。从表内数字看，VAR-d30-re 的 FID 和 IS 占优，推理时间更短。但这些模型的训练数据、训练预算、采样策略和部分结果来源并不完全统一，尤其 VAR-d30-re 使用 rejection sampling。

4.2 ImageNet 512 × 512 补充结果

Table 2: **ImageNet 512×512 conditional generation.**
†: quoted from MaskGIT [17]. “-s”: a single shared AdaLN layer is used due to resource limitation.

Type	Model	FID↓	IS↑	Time
GAN	BigGAN [13]	8.43	177.9	—
Diff.	ADM [26]	23.24	101.0	—
Diff.	DiT-XL/2 [63]	3.04	240.8	81
Mask.	MaskGIT [17]	7.32	156.0	0.5 [†]
AR	VQGAN [30]	26.52	66.8	25 [†]
VAR	VAR-d36-s	2.63	303.2	1

图 4.2 原论文 Table 2: ImageNet 512×512 conditional generation.

图 4.2 报告 ImageNet 512 × 512 conditional generation。VAR-d36-s 的 FID 为 2.63，IS 为 303.2，相对时间为 1；DiT-XL/2 的 FID 为 3.04，IS 为 240.8，相对时间为 81；VQGAN 的 FID 为 26.52，IS 为 66.8，相对时间为 25。

该表补充说明 VAR 在更高分辨率下仍保持竞争力。不过它的比较项少于图 4.1，且 VAR-d36-s 使用单个共享 AdaLN 层，属于资源限制下的特殊设置。

4.3 Scaling laws

论文的另一项重点是展示 VAR 具备类似 LLM 的 scaling behavior。Section 5.2 说明，作者训练了 12 个不同规模的 VAR，参数量从 18.5M 到 2.0B，使用 ImageNet 训练集 1.28 M 张图像。原文还写到，在论文采用的 VQVAE 设置下，每个 epoch 约对应 870B image tokens，最大训练 token 数达到 305B。




图 4.3 原论文 Figure 5: Scaling laws with VAR transformer size N .

图 4.3 展示了模型参数量 N 与测试损失、token error rate 之间的幂律拟合，caption 报告 Pearson correlation coefficients 接近 -0.998 。正文给出的拟合关系包括：

$$L_{\text{last}} = (2.0 \cdot N)^{-0.23}, \quad L_{\text{avg}} = (2.5 \cdot N)^{-0.20}. \quad (4.1)$$

$$\text{Err}_{\text{last}} = (4.9 \cdot 10^2 N)^{-0.016}, \quad \text{Err}_{\text{avg}} = (6.5 \cdot 10^2 N)^{-0.010}. \quad (4.2)$$

图 4.4 则展示 optimal training compute C_{min} 与损失和 error rate 的关系。正文给出的拟合式为：

$$L_{\text{last}} = (2.2 \cdot 10^{-5} C_{\text{min}})^{-0.13}, \quad (4.3)$$

$$L_{\text{avg}} = (1.5 \cdot 10^{-5} C_{\text{min}})^{-0.16}, \quad (4.4)$$

$$\text{Err}_{\text{last}} = (8.1 \cdot 10^{-2} C_{\text{min}})^{-0.0067}, \quad (4.5)$$

$$\text{Err}_{\text{avg}} = (4.4 \cdot 10^{-2} C_{\text{min}})^{-0.011}. \quad (4.6)$$




图 4.4 原论文 Figure 6: Scaling laws with optimal training compute C_{min} .

这一部分与 LLM 研究中的 scaling law 分析最为接近。除最终 FID 外，作者还试图说明 VAR 可以像语言模型一样用小模型预测大模型趋势。图 4.5 进一步用样例展示模型规模和训练计算量增加后的视觉变化。




图 4.5 原论文 Figure 7: Scaling model size N and training compute C improves visual fidelity and soundness.

第 5 章 零样本下游任务

图 5.1 展示了 in-painting、out-painting 和 class-conditional editing。Section 6 说明，in-painting 与 out-painting 使用 VAR-d30，mask 外的 ground-truth tokens 通过 teacher forcing 固定，模型只生成 mask 内 tokens，并且不注入 class label。class-conditional editing 则在 bounding box 内条件生成，并注入目标类别标签。




图 5.1 原论文 Figure 8: Zero-shot evaluation in downstream tasks containing in-painting, out-painting, and class-conditional editing.

图 5.1 表明，VAR 在补全未知区域方面具有一定潜力。由于生成过程以尺度为单位，模型可以在给定部分上下文的情况下补全未知区域，而不必像传统 raster AR 那样只能依赖单向前缀。换句话说，VAR 的 coarse-to-fine 结构更便于把已知区域作为约束条件。

第 6 章 消融实验：主要增益来源

图 6.1 是全文对方法贡献较有支撑力的实验之一。第一行 AR baseline 为 227M 参数，FID 为 18.65，相对 cost 为 1。第二行仅将建模方式从 AR 改为 VAR，参数量为 207M，FID 降到 5.22，相对 cost 只有 0.013。这说明最主要的提升来自 next-token 到 next-scale 的建模目标变化，而不是来自额外组件。

Table 3: Ablation study of VAR. The first two rows compare GPT-2-style transformers trained under AR or VAR algorithm without any bells and whistles. Subsequent lines show the influence of VAR enhancements. “AdaLN”: adaptive layernorm. “CFG”: classifier-free guidance. “Attn. Norm.”: normalizing q and k to unit vectors before attention. “Cost”: inference cost relative to the baseline. “ Δ ”: FID reduction to the baseline.

	Description	Para.	Model	AdaLN	Top- k	CFG	Cost	FID↓	Δ
1	AR [30]	227M	AR	✗	✗	✗	1	18.65	0.00
2	AR to VAR	207M	VAR- $d16$	✗	✗	✗	0.013	5.22	−13.43
3	+AdaLN	310M	VAR- $d16$	✓	✗	✗	0.016	4.95	−13.70
4	+Top- k	310M	VAR- $d16$	✓	600	✗	0.016	4.64	−14.01
5	+CFG	310M	VAR- $d16$	✓	600	2.0	0.022	3.60	−15.05
5	+Attn. Norm.	310M	VAR- $d16$	✓	600	2.0	0.022	3.30	−15.35
6	+Scale up	2.0B	VAR- $d30$	✓	600	2.0	0.052	1.73	−16.85

图 6.1 原论文 Table 3: Ablation study of VAR.

后续组件的贡献也较为清晰：加入 AdaLN 后 FID 为 4.95；加入 Top- $k = 600$ 后 FID 为 4.64；加入 CFG, ratio 为 2.0 后 FID 为 3.60；加入 attention normalization 后 FID 为 3.30；最终扩展到 VAR- $d30$ 、2.0B 参数后 FID 为 1.73。

主表图 4.1 是跨模型家族比较，容易受到训练预算、采样策略和实现细节影响；消融表则更明确地展示了“把 AR 换成 VAR”带来的变化。

第 7 章 批判性讨论

7.1 强点

第一，问题重定义具有启发性。图像没有天然的一维顺序，传统 raster AR 是把语言模型顺序迁移到图像。VAR 把顺序换成尺度，既符合视觉层级结构，也显著改善推理并行度。

第二，实验设计比较完整。论文没有只报主表 FID，而是同时讨论质量、速度、数据效率、scaling laws、zero-shot，并给出较为清晰的 ablation。尤其图 6.1 使得“方法本身有效”这个判断更有依据。

第三，架构选择相对克制。VAR Transformer 没有依赖大量复杂 LLM 组件，tokenizer 也基本沿用 VQGAN，只改多尺度量化层。因而论文贡献较集中：关键变化在于自回归单位和顺序，而不是组件组合。

7.2 保留意见

第一，论文对 raster AR 的理论批评需要更精确地理解。任意联合分布都可以按任意顺序分解，raster order 的问题并不是“数学上不能建模”，而是它对图像结构不自然、采样低效、空间局部性利用差。

第二，跨模型比较存在口径差异。图 4.1 汇总了不同模型家族，训练数据、训练 epoch、采样策略、是否使用 rejection sampling 都不完全一致。VAR-d30-re 的结果具有较强竞争力，但它使用 rejection sampling，和不带 rejection sampling 的模型相比时应当保留这个条件。

第三，scaling law 的外推范围仍有限。论文的 scaling law 基于 ImageNet、特定 VQVAE tokenizer、class-conditional generation，以及最高 2.0B 参数的 VAR。它说明当前设置下存在平滑趋势，但还没有证明该趋势会自然延伸到文本条件生成、开放域图像生成、视频生成或更大规模数据。

第四，zero-shot 部分主要是定性展示。图 5.1 说明 VAR 有补全和编辑潜力，但缺少定量指标和系统比较，因此不宜把它写成已经充分验证的下游泛化能力。

第 8 章 总体评价

VAR 的价值不只是证明某个 AR 模型在 ImageNet 上获得了更好的 FID，而是提供了一种有参考价值的视觉生成建模方式：当一个模态没有天然的一维顺序时，不应机械复用语言模型的 next-token order，而应重新设计更适合该模态结构的数据顺序。

从这个角度看，VAR 把图像顺序从 raster token sequence 改成 scale sequence，能够解释其质量和速度优势。它同时回应了传统视觉 AR 的三个问题：采样过慢、空间结构被展平削弱、下游补全任务受单向前缀限制。论文实验表明，这个设计在 ImageNet 条件生成上能同时提升质量和效率，并且在模型规模和训练计算量上表现出清晰的幂律趋势。

后续值得关注的问题是 tokenizer。论文 Section 6 也承认，本文主要固定 VQVAE 架构和训练方式，advanced tokenizer 是正交改进方向。如果多尺度量化换成更强的视觉 tokenizer，VAR 的上限可能继续提高；如果 tokenizer 的重建质量或 codebook 表达受限，即使进一步增大 VAR Transformer，也会受到第一阶段瓶颈限制。另一个关键方向是 text-to-image。论文把 text-prompt generation 作为 future work，没有给出实验结果，因此 VAR 是否能迁移到开放文本条件生成，仍需要单独验证。

正文总字数为：3241。