



北京邮电大学

Beijing University of Posts and Telecommunications

贝叶斯模型

戚 琦

网络与交换技术国家重点实验室 网络智能研究中心 科研楼511


qiqi8266@bupt.edu.cn

13466759972





回顾：监督学习





- 贝叶斯决策论
- 朴素贝叶斯分类器
- 半朴素贝叶斯分类器
- 贝叶斯网络




■ 条件概率

描述两个有**因果关系**的随机事件之间的概率关系， $p(b|a)$ 定义为在**事件a****发生的前提**下事件b发生的概率。

■ 贝叶斯公式

两个随机事件之间的关系：

$$p(b|a) = \frac{p(a|b)p(b)}{p(a)}$$



贝叶斯，英国数学家。1702年出生于伦敦，做过牧师。1742年成为英国皇家学会会员。1763年4月7日逝世。贝叶斯在数学方面主要研究概率论。他首先将归纳推理法用于概率论基础理论，并创立了**贝叶斯统计理论**，对于统计决策函数、统计推断、统计的估算等做出了贡献。

- 分类问题：特征向量取值 x 与样本所属类型 y 有因果关系。
因为样本属于类型 y ，所以具有特征值 x 。
- 分类器：已知样本的特征向量 x 的条件下反推样本所属的类别。根据贝叶斯公式有

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

$p(x)$ 特征向量的分布

$p(y)$ 类别出现的概率，即先验分布

$p(x|y)$ 每个类别下，样本具有某个特征的条件概率

$p(y|x)$ 样本属于每一类的概率，即后验概率

$$h^*(x) = \arg \max_{c \in y} P(c|x)$$

对于每个样本 x ，选择使后验概率 $P(c|x)$ 最大的类别标记

现实中难以直接获得

最小化分类错误率的**贝叶斯最优分类器**


- 机器学习所要实现的是基于有限的训练样本尽可能准确地估计出后验概率。
- 两种基本策略：
 - 判别式模型
直接建模 $P(c | x)$ ：决策树、BP 神经网络、SVM
 - 生成式模型
先建模联合概率分布 $P(x, c)$ ，再计算 $P(c | x)$ ：

$$P(c|x) = \frac{P(x, c)}{P(x)}$$

贝叶斯分类器、GAN、VAE等


Discriminative vs. Generative

Discriminative



- Only care about estimating the conditional probabilities
- Very good when underlying distribution of data is really complicated (e.g. texts, images, movies)


Generative



- Model observations (x,y) first, then infer $p(y|x)$
- Good for missing variables, better diagnostics
- Easy to add prior knowledge about data



■ 基于贝叶斯定理，生成式模型可写成





- 贝叶斯决策论
- 朴素贝叶斯分类器
- 半朴素贝叶斯分类器
- 贝叶斯网络



给定类标号 y ，朴素贝叶斯分类器在估计类条件概率时**假设属性之间条件独立**。
条件独立假设可以形式化的表达如下：

$$P(X | Y = y) = \prod_{i=1}^n P(x_i | Y = y)$$

其中每个训练样本可用一个属性向量 $X=(x_1, x_2, x_3, \dots, x_n)$ 表示，各个属性之间条件独立。

对于一篇文章 “Good good study, Day day up.”

用一个文本特征向量来表示： $x=(\text{Good}, \text{good}, \text{study}, \text{Day}, \text{day}, \text{up})$

一般各个词语之间肯定不是相互独立的，有一定的上下文联系。但在朴素贝叶斯文本分类时，我们假设个单词之间没有联系，可以用一个文本特征向量来表示这篇文章，这就是“朴素”的来历。

朴素贝叶斯如何工作

- 有了条件独立假设，就不必计算X和Y的每一种组合的类条件概率，只需对给定的Y，计算每个 x_i 的条件概率。不需要很大的训练集就能获得较好的概率估计，更实用。
- 估计分类属性的条件概率： $P(x_i | Y=y)$ 怎么计算呢？

一般根据类别y下包含属性 x_i 的实例的比例来估计。

以文本分类（比如积极或消极）为例， x_i 表示一个单词，

$$P(x_i | Y=y) = \frac{\text{该类别下包含单词的}x_i\text{的文章总数}}{\text{该类别下的文章总数}}$$

贝叶斯分类器举例

假设给出如下训练样本数据（14天打球情况、4种环境变化），学习的目标是根据给定的天气状况判断对PlayTennis这个请求的回答是Yes还是No。

先验概率

$$p(y = \text{yes}) = 9/14$$

$$p(y = \text{no}) = 5/14$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No



*回顾决策树


✓ 决策树构造实例

✎ 划分方式：4种


✎ 问题：谁当根节点呢？

✎ 依据：信息增益


1. 基于天气的划分




2. 基于温度的划分




3. 基于湿度的划分



4. 基于有风的划分



贝叶斯分类器举例



利用训练数据**计算后验概率** $P(\text{Yes} | x)$ 和 $P(\text{No} | x)$,

测试样本, 如果 $P(\text{Yes} | x) > P(\text{No} | x)$, 那么分类为Yes, 否则为No。

朴素贝叶斯分类器来分类左侧测试样本：

$$x = \begin{bmatrix} \text{outlook} = \text{sunny} \\ \text{temperature} = \text{cool} \\ \text{humidity} = \text{high} \\ \text{wind} = \text{strong} \end{bmatrix}$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D8	Sunny	Mild	High	Weak	No
D14	Rain	Mild	High	Strong	No
D6	Rain	Cool	Normal	Strong	No

$$P(\text{Outlook} = \text{Sunny} | \text{No}) = 3/5$$

$$P(\text{Temperature} = \text{Cool} | \text{No}) = 1/5$$

$$P(\text{Humidity} = \text{High} | \text{No}) = 4/5$$

$$P(\text{Wind} = \text{Strong} | \text{No}) = 3/5$$

$$\longrightarrow P(X | Y = \text{NO}) = \frac{3}{5} * \frac{1}{5} * \frac{4}{5} * \frac{3}{5} = \frac{36}{625} \quad p(Y = \text{no}) = 5/14$$

$$\longrightarrow P(X | Y = \text{NO}) * P(Y = \text{NO}) = \frac{36}{625} * \frac{5}{14} = \frac{18}{875}$$



贝叶斯分类器举例

$$P(\text{Outlook} = \text{Sunny} | \text{Yes}) = 2/9$$

$$P(\text{Temperature} = \text{Cool} | \text{Yes}) = 3/9$$

$$P(\text{Humidity} = \text{High} | \text{Yes}) = 3/9$$

$$P(\text{Wind} = \text{Strong} | \text{Yes}) = 3/9$$

$$P(P = \text{yes}) = 9/14$$

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D7	Overcast	Cool	Normal	Strong	Yes
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes

$$P(X | Y = \text{YES}) = \frac{2}{9} * \frac{3}{9} * \frac{3}{9} * \frac{3}{9} = \frac{2}{283}$$

$$P(X | Y = \text{YES})P(P = \text{YES}) = \frac{2}{9} * \frac{3}{9} * \frac{3}{9} * \frac{3}{9} * \frac{9}{14} = \frac{1}{189}$$

所以该样本
分类为No



$$P(X | Y = \text{NO})P(Y = \text{NO}) = \frac{18}{875} > P(X | Y = \text{YES})P(P = \text{YES}) = \frac{1}{189}$$



朴素贝叶斯分类器表达式

由于对所有类别来说 $P(\mathbf{x})$ 相同, 因此基于式(7.6)的贝叶斯判定准则有

周志华, 《机器学习》

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c), \quad (7.15)$$

这就是朴素贝叶斯分类器的表达式.

显然, 朴素贝叶斯分类器的训练过程就是基于训练集 D 来估计类先验概率 $P(c)$, 并为每个属性估计条件概率 $P(x_i | c)$.

令 D_c 表示训练集 D 中第 c 类样本组成的集合, 若有充足的独立同分布样本, 则可容易地估计出类先验概率

$$P(c) = \frac{|D_c|}{|D|}. \quad (7.16)$$

离散

$$P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}.$$

连续

$$p(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right).$$

例如, 高斯分布



- 若某个属性值在训练集中没有与某个类同时出现过，则直接计算连乘式的概率值为 0，导致分类结果显然不合理
- 为了避免其他属性携带的信息被训练集中未出现的属性值“抹去”，在估计概率值时通常要进行“拉普拉斯修正”
- 令 N 表示数据集 D 中可能的类别数， N_i 表示第 i 个属性可能的取值数，则

$$\text{先验概率} \quad \hat{P}(c) = \frac{|D_c| + 1}{|D| + N}$$

$$\text{类条件概率} \quad \hat{P}(x_i|c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i}$$

拉普拉斯修正，实际上是假设了属性与类别均匀分布

- 若任务对预测速度要求较高：
计算所有概率估值存储，使用时“查表”
- 若任务数据更替频繁：
使用“懒惰学习”，即先不进行任务训练，收到预测请求时再估值
- 若任务数据不断增加：
使用“增量学习”，基于现有估值，对新样本涉及的概率估值进行修正



- 贝叶斯理论
- 朴素贝叶斯分类器
- 半朴素贝叶斯分类器
- 贝叶斯网络



半朴素贝叶斯分类器


- 为了降低贝叶斯公式中估计后验概率的困难，朴素贝叶斯分类器采用了**属性条件独立性假设**；
- 对属性条件独立假设进行一定程度的放松，由此产生了一类称为“**半朴素贝叶斯分类器**”。
- 半朴素贝叶斯分类器**最常用**的一种策略：“独依赖估计” (**One-Dependent Estimator, ODE**)，假设每个属性在类别之外**最多仅依赖一个其他属性**，即

$$P(c|\mathbf{x}) \propto P(c) \prod_{i=1}^d P(x_i | c, \underline{pa_i})$$

pa_i 为属性 x_i 所依赖的属性，称为 x_i 的**父属性**


- 对每个属性 x_i ，若其父属性 pa_i 已知，则可估计概率值 **$P(x_i | c, pa_i)$** ，于是问题的**关键**转化为如何确定每个属性的父属性。

- **SPODE**(Super-Parent ODE) 假设所有属性都依赖于同一属性，称为“**超父**”(Super-Parent)，可通过交叉验证等模型选择方法来确定超父属性。
- **TAN**(Tree Augmented naïve Bayes) 以属性间的**条件“互信息”**(mutual information) 为边的权重，构建完全图，再利用最大带权生成树算法，仅保留强相关属性间的依赖性。




(a) NB

朴素贝叶斯



(b) SPODE

x_1 为超父



(c) TAN

互信息(Mutual Information)是信息论里一种有用的信息度量，可以看成是一个随机变量中包含的关于另一个随机变量的信息量，或者说是二个随机变量由于已知另一个随机变量而减少的不确定性

- 贝叶斯理论
- 朴素贝叶斯分类器
- 半朴素贝叶斯分类器
- 贝叶斯网络

1985年由Judea Pearl首先提出

- 把某个研究系统中涉及的**随机变量**，根据是否条件独立绘制在一个**有向图**中，就形成了贝叶斯网络。
- 贝叶斯网络（Bayesian Network），是**有向无环图模型**，也是一种**概率图模型**，借由有向无环图DAG中得知一组随机变量 $\{X_1, X_2 \dots X_n\}$ 及其n组**条件概率分布**的性质。
- 一般而言，贝叶斯网络的有向无环图中的**节点表示随机变量**，它们可以是可观察到的变量，或隐变量、未知参数等。连接两个节点的**箭头代表此两个随机变量是具有因果关系**（或非条件独立）。若两个节点间以一个单箭头连接在一起，表示其中一个节点是“**因(parents)**”，另一个是“**果(children)**”，两节点就会产生一个**条件概率值**。
- 每个结点在给定其直接前驱时，条件独立于其非后继。

- 概率图模型：用图来表示变量概率依赖关系的理论
 - 结合概率论与图论，利用图表示与模型有关的变量的联合概率分布
- { 贝叶斯网络 (Bayesian Network)：有向图结构表示
- { 马尔可夫网络 (Markov Network)：无向图结构表示


概率图模型包括朴素贝叶斯模型、最大熵模型、隐马尔可夫模型、条件随机场、主题模型等，在机器学习的诸多场景中都有着广泛的应用



常见的贝叶斯网络

- 一个简单的贝叶斯网络

$$p(a, b, c) = p(c|a, b)p(b|a)p(a)$$




- 全连接贝叶斯网络：每一对结点之间都有边连接

$$p(x_1, \dots, x_K) = p(x_K | x_1, \dots, x_{K-1}) \dots p(x_2 | x_1) p(x_1)$$

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(X_i = x_i | X_{i+1} = x_{i+1}, \dots, X_n = x_n)$$

- 正常的贝叶斯网络：有些边缺失，直观上

- x_1 和 x_2 独立
- x_6 和 x_7 在 x_4 给定的条件下独立
- $x_1, x_2, \dots, x_7$ 的联合分布：




$$p(x_1)p(x_2)p(x_3)p(x_4|x_1, x_2, x_3)p(x_5|x_1, x_3)p(x_6|x_4)p(x_7|x_4, x_5)$$






贝叶斯网络的结构形式

1. head-to-head



$p(a, b, c) = p(a)p(b)p(c|a, b)$ 成立,
即在c未知的条件下, a、b被阻断
(blocked), 是独立的, 称之为
head-to-head条件独立。

2. tail-to-tail




在c未知的条件下: $p(a, b, c) = p(c)p(a|c)p(b|c)$, 此时, 无法得出
 $p(a, b) = p(a)p(b)$, 即c未知时, a、b不独立;

在c已知的条件下: $p(a, b|c) = \frac{p(a, b, c)}{p(c)}$, 将 $p(a, b, c) = p(c)p(a|c)p(b|c)$,
带入式子得到: $p(a, b|c) = p(a|c)p(b|c)$, 即c已知时, a、b独立。



贝叶斯网络的结构形式

3. head-to-tail



➤ **c未知时:**

$p(a, b, c) = p(c)p(a|c)p(b|c)$, 此时, 无法得出 $p(a, b) = p(a)p(b)$, 即**c未知时, a、b不独立**;

➤ **c已知时:**

$p(a, b|c) = \frac{p(a, b, c)}{p(c)}$, 且根据 $p(a, c) = p(a)p(c|a) = p(c)p(a|c)$, 可得到:

$$p(a, b|c) = \frac{p(a, b, c)}{p(c)} = \frac{p(a)p(c|a)*p(b|c)}{p(c)} = \frac{p(a, c)p(b|c)}{p(c)} = p(a|c)p(b|c)$$

在**c给定的条件下, a, b被阻断(blocked)**, 是独立的, 称之为**head-to-tail条件独立**。

head-to-tail是一个链式网络



在 x_i 给定的条件下, x_{i+1} 的分布和 $x_1, x_2 \dots x_{i-1}$ 条件独立

➡ x_{i+1} 的分布状态只和 x_i 有关, 和其他变量条件独立。


➡ 当前状态只跟上一状态有关, 跟上上或上上之前的状态无关-----马尔科夫链 (Markov chain)

通过先验知识，根据节点因果关系构建


节点X的条件概率： $P(X | \text{parent}(X))$

$P(S, C, B, X, D) =$

$P(S) P(C|S) P(B|S) P(X|C,S) P(D|C,B)$




所有节点的联合概率 2^5



两个依赖的父节点就是4行 (00,01,10,11)

贝叶斯网络举例



全部随机变量的联合分布

$$P(x_1, \dots, x_n) = \prod_{i=1}^n P(x_i | \text{parents}(X_i))$$

$$P(j \wedge m \wedge a \wedge \neg b \wedge \neg e)$$

$$= P(j|a)P(m|a)P(a|\neg b, \neg e)P(\neg b)P(\neg e)$$

$$= 0.9 \times 0.7 \times 0.001 \times 0.999 \times 0.998$$

$$\approx 0.00063$$

盗窃报警，地震也报警，警报响后，John可以打电话，Mary也可以打电话

求：John打了电话，Mary也打了电话，警报也响了，但是没有盗窃发生，也没有地震的概率？

总结：判别模型与生成模型

假设有四个samples:

	sample 1	sample 2	sample 3	sample 4
x	0	0	1	1
y	0	0	0	1

生成模型:

	y = 0	y = 1
x = 0	1/2	0
x = 1	1/4	1/4

判别模型:

	y = 0	y = 1
x = 0	1	0
x = 1	1/2	1/2

同一套数据，
统计方法不同

拓展：样本服从某种分布

4.2.2 连续型特征

如果特征向量的分量是连续型随机变量,可以假设它们服从一维正态分布,称为正态朴素贝叶斯分类器。根据训练样本集可以计算出正态分布的均值与方差,这可以通过最大似然估计得到。这样得到概率密度函数为

$$f(x_i = x | y = c) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

连续型随机变量不能计算它在某一点的概率,因为它在任何一点处的概率为0。直接用概率密度函数的值替代概率值,得到的分类器为

$$\arg \max_c p(y = c) \prod_{i=1}^n f(x_i | y = c)$$

对于二分类问题可以做进一步简化。假设正负样本的类别标签分别为+1和-1,特征向量属于正样本的概率为

$$p(y = +1 | \mathbf{x}) = p(y = +1) \frac{1}{p(\mathbf{x})} \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}\right)$$

其中, μ_i 为第*i*个特征的均值, σ_i 为第*i*个特征的标准差。对上式两边取对数得

$$\begin{aligned} \ln p(y = +1 | \mathbf{x}) &= \ln \frac{p(y = +1)}{p(\mathbf{x})} + \sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi}\sigma_i} \exp\left(-\frac{(x_i - \mu_i)^2}{2\sigma_i^2}\right) \right) \\ &= \ln \frac{p(y = +1)}{p(\mathbf{x})} + \sum_{i=1}^n \left(\ln \frac{1}{\sqrt{2\pi}\sigma_i} - \frac{(x_i - \mu_i)^2}{2\sigma_i^2} \right) \end{aligned}$$

整理简化得

$$\ln p(y = +1 | \mathbf{x}) = \sum_{i=1}^n c_i (x_i - \mu_i)^2 + c$$

其中, c 和 c_i 都是常数, c_i 仅由 σ_i 决定。同样可以得到样本属于负样本的概率。在分类时只需要比较这两个概率对数值的大小,如果

$$\ln p(y = +1 | \mathbf{x}) > \ln p(y = -1 | \mathbf{x})$$

变形后得到

$$\ln p(y = +1 | \mathbf{x}) - \ln p(y = -1 | \mathbf{x}) > 0$$

时将样本判定为正样本,否则判定为负样本。

对于特征 x ,假设某一类所有训练样本该特征的取值为 $x_i, i=1, \dots, l$ 。根据一维正态分布的最大似然估计结果,此类样本该特征所服从的正态分布的均值和方差分别为

$$\begin{aligned} \mu &= \frac{1}{l} \sum_{i=1}^l x_i \\ \sigma^2 &= \frac{1}{l} \sum_{i=1}^l (x_i - \mu)^2 \end{aligned}$$

4.3 正态贝叶斯分类器

下面考虑更一般的情况,假设样本的特征向量服从多维正态分布,此时的贝叶斯分类器称为正态贝叶斯(Normal Bayes)分类器。

假设特征向量服从 n 维正态分布, 其中 μ 为均值向量, Σ 为协方差矩阵。类条件概率密度函数为

$$p(x | c) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right)$$

其中, $|\Sigma|$ 是协方差矩阵的行列式, Σ^{-1} 是协方差矩阵的逆矩阵。图 4-1 是二维正态分布的概率密度函数。




图 4.1 二维正态分布的概率密度函数

在接近均值处, 概率密度函数的值大; 在远离均值处, 概率密度函数的值小。正态贝叶斯分类器训练时根据训练样本估计每一类条件概率密度函数的均值与协方差矩阵。另外还需要计算协方差矩阵的行列式和逆矩阵。由于协方差矩阵是实对称矩阵, 因此一定可以对称化, 可以借助奇异值分解来计算行列式和逆矩阵。对协方差矩阵进行奇异值分解, 有

$$\Sigma = U W U^T$$

其中, W 为对角阵, 其对角元素为矩阵的特征值; U 为正交矩阵, 它的列为协方差矩阵的特征值对应的特征向量。计算 Σ 的逆矩阵可以借助该分解:

$$(\Sigma)^{-1} = (U W U^{-1})^{-1} = U W^{-1} U^{-1} = U W^{-1} U^T$$

对角矩阵的逆矩阵仍然为对角矩阵, 逆矩阵主对角元素为矩阵主对角元素的倒数; 正交矩阵的逆矩阵为其转置矩阵。根据上式可以很方便地计算出逆矩阵 Σ^{-1} ; 行列式 $|\Sigma|$ 也很容易被算出, 由于正交矩阵的行列式为 1, 因此, Σ 的行列式等于矩阵 W 的行列式, 而 W 的行列式又等于所有对角元素的乘积。

还有一个没有解决的问题是如何根据训练样本估计出正态分布的均值向量和协方差矩阵。通过最大似然估计和矩估计都可以得到正态分布的这两个参数。样本的均值向量就是均值向量的估计值, 样本的协方差矩阵就是协方差矩阵的估计值。

下面给出正态贝叶斯分类器的训练算法。训练算法的核心为计算样本的均值向量、协方差矩阵, 以及对协方差矩阵进行奇异值分解, 具体流程如下。

(1) 计算每一类训练样本的均值 μ 和协方差矩阵 Σ 。

(2) 对协方差矩阵进行奇异值分解, 得到 U , 然后计算所有特征值的逆, 得到 W^{-1} , 同时还计算出 $\ln(|\Sigma|)$ 。

拓展: 样本服从某种分布

假设某一类所有训练样本的特征向量为 $x_i, i=1, \dots, l$ 。根据多维正态分布的最大似然估计结果,此类样本特征向量所服从的正态分布的均值向量和协方差矩阵分别为

$$\mu = \frac{1}{l} \sum_{i=1}^l x_i$$

$$\Sigma = \frac{1}{l} \sum_{i=1}^l (x_i - \mu)(x_i - \mu)^T$$

4.3.2 预测算法

在预测时需要寻找具有最大条件概率的那一类,即最大化后验概率(Maximum A Posteriori, MAP),根据贝叶斯公式有

$$\arg \max_c (p(c | x)) = \arg \max_c \left(\frac{p(c)p(x | c)}{p(x)} \right)$$

假设每个类的概率 $p(c)$ 相等, $p(x)$ 对于所有类都是相等的,因此,等价于求解该问题:

$$\arg \max_c (p(x | c))$$

也就是计算每个类的 $p(x | c)$,然后取最大的那个。对 $p(x | c)$ 取对数,有

$$\ln(p(x | c)) = \ln \left(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} \right) - \frac{1}{2} ((x - \mu)^T \Sigma^{-1} (x - \mu))$$

进一步简化为

$$\ln(p(x | c)) = -\frac{n}{2} \ln(2\pi) - \frac{1}{2} \ln(|\Sigma|) - \frac{1}{2} ((x - \mu)^T \Sigma^{-1} (x - \mu))$$

其中, $-\frac{n}{2} \ln(2\pi)$ 是常数,对所有类都是相同的。求上式的最大值等价于求下式的最小值:

$$\ln(|\Sigma|) + ((x - \mu)^T \Sigma^{-1} (x - \mu))$$

其中, $\ln(|\Sigma|)$ 可以根据每一类的训练样本预先计算好,与 x 无关,不用重复计算。预测时只需要根据样本 x 计算 $(x - \mu)^T \Sigma^{-1} (x - \mu)$ 的值,而 Σ^{-1} 也是在训练时计算好的,不用重复计算。

下面考虑更特殊的情况,问题可以进一步简化。如果协方差矩阵为对角矩阵 $\sigma^2 I$,上面的值可以写成

$$\ln(p(x | c)) = -\frac{n}{2} \ln(2\pi) - 2n \ln \sigma - \frac{1}{2} \left(\frac{1}{\sigma^2} (x - \mu)^T (x - \mu) \right)$$

其中:

$$\ln(|\Sigma|) = \ln \sigma^{2n} = 2n \ln \sigma$$

$$\Sigma^{-1} = \frac{1}{\sigma^2} I$$

对于二分类问题,如果两个类的协方差矩阵相等,分类判别函数是线性函数:

$$\text{sgn}(w^T x + b)$$

这和朴素贝叶斯分类器的情况是一样的。如果协方差矩阵是对角矩阵,则 Σ^{-1} 同样是对角矩阵,上面的公式同样可以简化,这里不再详细讨论。

4.4 实验程序

下面通过实验程序介绍贝叶斯分类器的使用。程序基于 sklearn 开源库,使用 iris 数据集。iris 数据集包含 3 类鸢尾花的数据,分别为 Setosa, Versicolour, Virginica, 每类 50 个样