



北京邮电大学

Beijing University of Posts and Telecommunications

支持向量机模型

戚 琦

网络与交换技术国家重点实验室 网络智能研究中心 科研楼511


qiqi8266@bupt.edu.cn

13466759972





回顾：监督学习



- 支持向量机基本概念---线性可分类问题
- 非线性问题
- 对偶问题

推荐书籍 《统计学习方法》

视频课程：浙江大学胡老师 《机器学习》


台湾大学Hsuan-Tien Lin 《Machine Learning Techniques》


- Vapnik 从1960年开始关于统计学习理论研究
- 1995年Vapnik发展了支持向量机理论
- 支持向量机是基于统计学习理论的一种实用的机器学习方法
- 支持向量机具有优美的数学表达
- SVM在解决小样本、非线性及高维模式识别问题中表现出许多特有的优势，并能够推广应用到函数拟合等其他机器学习问题中




Vladimir
Naumovich Vapnik,
俄罗斯统计学家、
数学家

机器学习算法的时间线来自于 Eren Golge






线性可分样本



非线性可分样本

■ 问题：无数条线，哪个直线是最好的






对于误差的容忍程度

线性可分


■ 第1类
● 第2类

- 如何定义这条线？
- 定义一个衡量每一条线的标准，每条线都能算出来一个性能指标
- 哪条线能让这个性能指标最大



好的决策边界：间隔大

■ 决策边界离两类数据应尽可能远




不唯一，
选择处于
中间位置
的线

d: 最大化间隔 (Margin)

将平行线插到的向量称为支持向量

让这条线平行移动，直到能够
插到某一个或几个圆圈为止

这个距离作为性能指标，绿色
线是这个距离最大的一条线





训练数据和标签: $(x_1, y_1) (x_2, y_2) \dots (x_n, y_n)$

$$x_1 = \begin{bmatrix} x_{11} \\ x_{12} \\ \dots \\ x_{1m} \end{bmatrix}$$

向量 标签 $y_i = 1 \quad y_i = -1$

线性模型: $(w, b) \quad w^T x + b = 0$ (超平面Hyperplane)

w : 向量, 维度与 x 一样

常数

要找到描述这个超平面的线性方程

通过所有 x 和 y 的取值, 来算出来 w 和 b

$$w = \begin{bmatrix} w_1 \\ w_2 \\ \dots \\ w_m \end{bmatrix}$$





线性可分的训练集

■ 一个训练集线性可分是指：


$$\{(x_i, y_i)\}, i = 1 \sim N$$

$\exists (w, b)$, 使：

对 $\forall i = 1 \sim N$, 有：


1. 若 $y_i = +1$, 则 $w^T x + b \geq 0$

2. 若 $y_i = -1$, 则 $w^T x + b \leq 0$



统一表示

$$y_i [w^T x + b] \geq 0$$



1963年


如果两类数据之间存在分离超平面，则称数据为**线性可分** (linearly Separable)。






*线性可分数据的超平面

- 当训练数据集线性可分时，存在无穷多个分离超平面可将两类数据正确分开。
- 感知机利用误分类最小的策略，求得分离超平面，但有无穷多个解
- 支持向量机利用间隔最大化求最优分离超平面，解唯一



- 针对分离超平面不唯一的问题，一种解决方法是使**分离超平面离两类数据尽量远**。
- 希望在两类数据之间有一条“**隔离带**”，而且这条隔离带越宽越好。
- 这就是所谓**最大间隔分类器**(maximal margin classifier); 俗称“最宽街道法”(widest street approach)，即在两类数据之间建一条最宽的街道。



■ 如何得到间隔最大的超平面

$w^T x + b = 0$ 与 $aw^T x + ab = 0$ 是同一个平面, $a \in \mathbb{R}^+$

点到平面的距离:

平面: $w_1 x + w_2 y + b = 0$

则 (x_0, y_0) 到此平面的距离:

$$d = \frac{|w_1 x_0 + w_2 y_0 + b|}{\sqrt{w_1^2 + w_2^2}}$$

向量 x_0 到平面的距离:

$w^T x + b = 0$ 的距离

$$d = \frac{w^T x_0 + b}{\|w\|}$$

$\|w\| = \sqrt{w_1^2 + w_2^2 + \dots + w_m^2}$

总结: SVM是最大化间隔的分类算法

优化问题

用 a 缩放 $(w, b) \longrightarrow (aw, ab)$

最终使其在支持向量 x_0 上有: $|w^T x_0 + b| = 1$

$$d = \frac{w^T x_0 + b}{\|w\|^2}$$

此时支持向量与平面的距离: $d = \frac{1}{\|w\|^2}$ 最小化 $\|w\|$, 其他点大于 d

y_i 取正负1, 可以协调两个类, 也可以改成任意整数, 差距就是 a


支持向量机做了一个优化问题

最小化 (Minimize)

$$\|w\|^2$$

约束条件 (Subject to)

$$y_i[w^T x + b] \geq 1 \quad (i=1 \sim N)$$



数据集如果线性可分，就能求得 w 和 b ，满足条件：

$$\min \frac{1}{2} \|w\|^2 = \frac{1}{2} (w_1^2 + w_2^2 + \dots + w_m^2)$$

$\frac{1}{2}$ 是为了求导方便

$$s.t. \quad y_i [w^T x_i + b] \geq 1 \quad (i=1 \sim N)$$


目标优化问题是一个凸优化问题中的一种二次规划问题

■ 二次规划 (quadratic programming)

- 目标函数是二次项；约束条件是一次项
- 无解或者一个极小值
- 二次规划是计算机已解决的问题，其局部极值就是全局极值

■ 用试探方法，求极值，例如梯度下降

■ 多维情况下很困难，有时人眼无法看到所有情况





- SVM是最大化间隔（Margin）的分类算法


- 优化问题

训练样本 $\{(x_i, y_i)\}_{i=1 \sim N}$

- 优化目标

$$\min \frac{1}{2} \|w\|^2$$

$$\begin{aligned} \text{s.t.} \quad & y_i [w^T x_i + b] \geq 1 \\ & (i = 1 \sim N) \end{aligned}$$



求解得到分离超平面

$$w^* \cdot x + b^* = 0$$

决策函数

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$

凸优化问题中的二次规划问题






- 支持向量机基本概念
- 非线性问题
 - 软间隔
 - 高维映射
 - 核函数
- 对偶问题





非线性---软间隔

- 训练数据中的**特异点**，**去掉**后，剩下大部分样本点组成的集合满足线性可分



- 引入“软间隔”的概念：**允许支持向量机在一些样本上不满足约束**，即允许一些实例位于街道之上或者位于错误的一侧，这样就称为软间隔分类



给每个样本，加一个**松弛变量**，让 w 和 b 满足条件

将线性不可分的学习问题转换为**凸二次规划问题**，即**软间隔最大化**

正则项

最小化: $\frac{1}{2} \|w\|^2 + \underbrace{C \sum_{i=1}^N \xi_i}_{\text{松弛变量}}$

约束条件: (1) $y_i [w^T x + b] \geq 1 - \xi_i$

(2) $\xi_i \geq 0, i=1 \sim N$



线性支持向量机

求解得到分离超平面 $w^* \cdot x + b^* = 0$ ，以及决策函数

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$




软间隔参数




尽可能在保持街道宽阔或限制间隔违例之间找到一个平衡

间隔或限制间隔违例之间的关系由超参数 C 控制， C 越大，间隔越窄，但是违例也越少，反之则间隔越宽，但是违例也越多。






$C = 1$




$C = 10$




$C = 100$

C越大优化问题更为发散



- C 越大越容易造成过拟合



仍然找直线，但是到一个高维空间中找直线



ϕ



定义一个高维映射 $\phi(x)$


低维 $x \longrightarrow \phi(x)$ 高维

例如，最简单的非线性可分问题：异或问题


$$x_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \in C_1 \quad x_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \in C_1$$

$$x_3 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \in C_2 \quad x_4 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \in C_2$$


$$x = \begin{bmatrix} a \\ b \end{bmatrix} \xrightarrow{\text{二维变成五维}} \phi(x) = \begin{bmatrix} a^2 \\ b^2 \\ a \\ b \\ ab \end{bmatrix}$$



$$\begin{aligned} \phi(x_1) &= \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \in C_1 & \phi(x_2) &= \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \in C_1 \\ \phi(x_3) &= \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{bmatrix} \in C_2 & \phi(x_4) &= \begin{bmatrix} 0 \\ 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} \in C_2 \end{aligned}$$




二维异或数据集




$$\phi(x)$$

高斯核或径向基函数核



高维空间中的异或数据



线性分类器变为一个超平面，
把空间分为2个部分

FIGURE 5.6. The two-dimensional input space $\mathbf{x}$ is mapped through a polynomial function f to $\mathbf{y}$. Here the mapping is $y_1 = x_1$, $y_2 = x_2$ and $y_3 \propto x_1 x_2$. A linear discriminant in this transformed space is a hyperplane, which cuts the surface. Points to the positive side of the hyperplane $\hat{H}$ correspond to category ω_1 , and those beneath it correspond to category ω_2 . Here, in terms of the $\mathbf{x}$ space, $\mathcal{R}_1$ is not simply connected. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

■ 关键思想

为了解决非线性分割问题, 将 x_i 变换到一个高维空间

- 输入空间: x_i 所在的空间
- 特征空间: 变换后 $\phi(x_i)$ 的空间

■ 如何变换 ?


- 利用一个适当的变换 ϕ , 使分类变得容易
- 特征空间中的线性算子等价于输入空间中的非线性算子

■ 变换可能出现的问题

- 难以得到一个好的分类且计算开销大

■ 需要同时解决两个问题

- 最小化 $\|w\|^2$ 能得到好的分类
- 进行高效的计算 (利用核函数技巧)





高维映射 $x \longrightarrow \phi(x)$

$$\begin{cases} y_i[w^T \phi(x_i) + b] \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases}$$

$\phi(x)$ 是无限维，无法求整体优化

定义 $\phi(x_1)$ 与 $\phi(x_2)$ 两个无限维向量 **内积**

⇒ **核函数 (Kernel Function)**

$$K(x_1, x_2) = \phi(x_1)^T \phi(x_2)$$

只要知道一个核函数，不知道无限维映射 $\phi(x_i)$ 的显示表达，仍然可以求解最优

为什么可以通过求内积代替显示 ϕ ---- 对偶问题！





- 假设知道了 K ，如何求解 $\phi(x_i)$ ，让优化问题可求解？
- 核函数也是有限制的， **K 要满足某种特定条件，才能拆成内积**， $K(x_1, x_2)$ 能写成 $\phi(x_1)^T \phi(x_2)$ 的充要条件：

(1) $K(x_1, x_2) = K(x_2, x_1)$ 交换性

(2) $\forall C_i, x_i, i = 1 \sim N$ ，有 半正定性

$$\sum_{i=1}^N \sum_{j=1}^N C_i C_j K(x_i, x_j) \geq 0$$



$$K(x_1, x_2) = \phi(x_1)^T \phi(x_2) \xrightarrow{\text{换符号}} K(x, y) = \phi(x)^T \phi(y)$$

■ 定义核函数

$$K(x, y) = (1 + x_1 y_1 + x_2 y_2)^2$$

■ 代入变换（2维变为6维）

$$\phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)$$

$$\phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) = (1, \sqrt{2}y_1, \sqrt{2}y_2, y_1^2, y_2^2, \sqrt{2}y_1y_2)$$

$$\langle \phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right), \phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) \rangle = (1 + x_1 y_1 + x_2 y_2)^2 = K(x, y) \quad \text{内积}$$

■ 内积可由 K 计算, 不必通过映射 $\phi(\cdot)$ 计算

■ 常用核函数

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	$\tanh$ 为双曲正切函数, $\beta > 0, \theta < 0$

- 基本经验：文本数据常用线性核，情况不明先尝试高斯核
程序实现时，可以调用相关的软件包

二阶多项式函数: $\phi_2(x)$

$$\phi_2(x) = (1, x_1, x_2, \dots, x_d, x_1^2, x_1x_2, \dots, x_1x_d, x_2x_1, x_2^2, \dots, x_2x_d, \dots, x_d^2)$$

$$\begin{aligned}\Phi_2(\mathbf{x})^T \Phi_2(\mathbf{x}') &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d \sum_{j=1}^d x_i x_j x'_i x'_j \\ &= 1 + \sum_{i=1}^d x_i x'_i + \sum_{i=1}^d x_i x'_i \sum_{j=1}^d x_j x'_j \\ &= 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')(\mathbf{x}^T \mathbf{x}')\end{aligned}$$

■ 计算复杂度为 $O(d)$, 而非 $O(d^2)$

image: Hsuan-Tien Lin



广义二阶多项式核

$$\begin{aligned}\Phi_2(\mathbf{x}) &= (1, x_1, \dots, x_d, x_1^2, \dots, x_d^2) \Leftrightarrow K_{\Phi_2}(\mathbf{x}, \mathbf{x}') = 1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2 \\ \Phi_2(\mathbf{x}) &= (1, \sqrt{2}x_1, \dots, \sqrt{2}x_d, x_1^2, \dots, x_d^2) \Leftrightarrow K_2(\mathbf{x}, \mathbf{x}') = 1 + 2\mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2 \\ \Phi_2(\mathbf{x}) &= (1, \sqrt{2\gamma}x_1, \dots, \sqrt{2\gamma}x_d, \gamma x_1^2, \dots, \gamma x_d^2) \\ &\Leftrightarrow K_2(\mathbf{x}, \mathbf{x}') = 1 + 2\gamma \mathbf{x}^T \mathbf{x}' + \gamma^2 (\mathbf{x}^T \mathbf{x}')^2\end{aligned}$$

■ 最常用的二阶核函数：

$$K_2(\mathbf{x}, \mathbf{x}') = (1 + \gamma \mathbf{x}^T \mathbf{x}')^2, \gamma > 0$$


- 不同的 γ 取值的对应相同维度的空间，但是不同的内积导致距离和边界都不相同

image: Hsuan-Tien Lin







广义二阶多项式核



$$(1 + 0.001 \mathbf{x}^T \mathbf{x}')^2$$



$$1 + \mathbf{x}^T \mathbf{x}' + (\mathbf{x}^T \mathbf{x}')^2$$



$$(1 + 1000 \mathbf{x}^T \mathbf{x}')^2$$

- 不同的 γ 取值对应的支持向量和间隔不同
- γ 是需要选择的超参数

image: Hsuan-Tien Lin



$$K_2(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^2 \text{ with } \gamma > 0, \zeta \geq 0$$

$$K_3(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^3 \text{ with } \gamma > 0, \zeta \geq 0$$

$\vdots$

$$K_Q(\mathbf{x}, \mathbf{x}') = (\zeta + \gamma \mathbf{x}^T \mathbf{x}')^Q \text{ with } \gamma > 0, \zeta \geq 0$$

- 多项式核支持向量机
- (γ, ζ, Q) 是需要选择的超参数

image: Hsuan-Tien Lin






- 无限维的特征变换 $\Phi(\mathbf{x})$
- $K(\mathbf{x}, \mathbf{x}') = \exp(-(\mathbf{x} - \mathbf{x}')^2)$

$$\begin{aligned}
 \text{when } \mathbf{x} = (x), \quad K(x, x') &= \exp(-(x - x')^2) \\
 &= \exp(-(x)^2) \exp(-(x')^2) \exp(2xx') \\
 &\stackrel{\text{Taylor}}{=} \exp(-(x)^2) \exp(-(x')^2) \left(\sum_{i=0}^{\infty} \frac{(2xx')^i}{i!} \right) \\
 &= \sum_{i=0}^{\infty} \left(\exp(-(x)^2) \exp(-(x')^2) \sqrt{\frac{2^i}{i!}} \sqrt{\frac{2^i}{i!}} (x)^i (x')^i \right) \\
 &= \Phi(x)^T \Phi(x')
 \end{aligned}$$


with infinite dimensional $\Phi(x) = \exp(-x^2) \cdot \left(1, \sqrt{\frac{2}{1!}}x, \sqrt{\frac{2^2}{2!}}x^2, \dots \right)$

- 一般形式: $K(\mathbf{x}, \mathbf{x}') = \exp(-\lambda(\mathbf{x} - \mathbf{x}')^2), \lambda > 0$






$$\exp(-1\|\mathbf{x} - \mathbf{x}'\|^2)$$



$$\exp(-10\|\mathbf{x} - \mathbf{x}'\|^2)$$



$$\exp(-100\|\mathbf{x} - \mathbf{x}'\|^2)$$

- λ 越大，越容易过拟合
- 高斯核支持向量机
- λ 是需要选择的参数

image: Hsuan-Tien Lin



- 支持向量机基本概念
- 非线性问题
- 对偶问题
 - 定义
 - 求解
 - 三类对偶问题
 - 算法

简单的二维空间求解

- Problem 1. $\min f(x)$
- Problem 2. $\min f(x) \quad \text{s.t. } g(x) = 0$
- Problem 3. $\min f(x) \quad \text{s.t. } g(x) \leq 0$


$$\begin{cases} \min f(x, y) \\ g(x, y) = 0 \end{cases} \quad \longleftrightarrow$$

$$\begin{cases} \min(x^2 + y^2) \\ x^2 y = 3 \end{cases}$$



$$\begin{cases} \nabla f = \lambda \nabla g \\ g(x, y) = 0 \end{cases} \quad \longleftrightarrow$$

$$\begin{cases} \begin{pmatrix} 2x \\ 2y \end{pmatrix} = \lambda \begin{pmatrix} 2xy \\ x^2 \end{pmatrix} \\ x^2 y = 3 \end{cases}$$




原问题 (prime problem)

$$\min f(w)$$

$$\begin{aligned} \text{s.t. } & g_i(w) \leq 0 (i \sim K) \\ & h_i(w) = 0 (i \sim M) \end{aligned}$$

引入
拉格朗日
乘子



定义: $L(w, \alpha, \beta)$

$$= f(w) + \sum_{i=1}^K \alpha_i g_i(w) + \sum_{i=1}^M \beta_i h_i(w)$$

$$= f(w) + \alpha^T g(w) + \beta^T h(w)$$



$$\begin{bmatrix} g_1(w) \\ g_2(w) \\ \vdots \\ g_K(w) \end{bmatrix} \quad \begin{bmatrix} h_1(w) \\ h_2(w) \\ \vdots \\ h_M(w) \end{bmatrix}$$

凸优化问题

目标函数 $f(w)$ 与约束函数 $g_i(w)$ 为连续可微凸函数
 $h_i(w)$ 为仿射函数 (即 $ax+b$ 的形式)


对偶问题—普适定义

■ 对偶问题定义 (Dual Problem)

最大化 $\theta(\alpha, \beta) = \inf\{L(w, \alpha, \beta)\}$

求最小值：所有 w ，求最小值

限制条件： $\alpha \geq 0$ (即 $\alpha_i \geq 0, i = 1 \sim K$)



- 限定 α 和 β 的情况下，遍历所有 w 求 L 的最小值，每确定一个 α 和 β 都能算出 L 的最小值
- 再针对所有的 α 和 β ，把这个最小值推高，即求 L 的最大值

θ ：所有下界里的最大值；比较大的更接近与原问题的解

*原问题与对偶问题

定理：如果 w^* 是原问题的解，而 α^* 和 β^* 是对偶问题解，则有 $f(w^*) \geq \theta(\alpha^*, \beta^*)$

证明： $\theta(\alpha^*, \beta^*) = \inf\{L(w, \alpha^*, \beta^*)\} \leq L(w^*, \alpha^*, \beta^*)$

固定 α^*, β^* 所有 w , 求最小

w^* 是原问题的解，带入 L 后，
 $L(w, \alpha^*, \beta^*)$ 一定小于某个特定的 w^*

$$\begin{aligned} &= f(w^*) + \sum_{i=1}^K \alpha_i^* \underbrace{g_i(w^*)}_{\leq 0} + \sum_{i=1}^M \beta_i^* \underbrace{h_i(w^*)}_{= 0} \\ &\leq f(w^*) \end{aligned}$$

*强对偶定理 (KKT条件)

定义: $G = f(w^*) - \theta(\alpha^*, \beta^*) \geq 0$ 为原问题与对偶问题的**间距** (Duality Gap)

强对偶定理: 若 $f(w)$ 为**凸函数**,
且 $g(w) = Aw + b, h(w) = Cw + d$,
则原问题与对偶问题间距为0, 即

$$f(w^*) = \theta(\alpha^*, \beta^*)$$

对 $\forall i = 1 \sim K$, $\alpha_i^* = 0$, 或 $g_i^*(w^*) = 0$

(KKT条件, KKT是三个人的名字)

希望 $\sum_{i=1}^K \alpha_i^* g_i(w^*) = 0$



对于某些特定优化问题, 可以证明
 $G=0$, 即原问题与对偶问题相等



原始问题比较难以求解, 通过构建其
对偶问题, 解决这个对偶问题得到其
原问题的下界 (在**弱对偶**情况下, 对
于最小化问题来说), 或者得到原问
题的解 (**强对偶**情况下)。

《凸优化》

- 无论原问题难度如何，对偶问题都是凸问题，凸问题是一类比较容易求解问题，当原问题是一个特别难的问题时，化简为对偶问题，相对容易求解；
- 转化为对偶问题后，引入的拉格朗日乘子数量是所有约束个数的总和，当原问题中变量个数（样本的维度），远小于约束个数时（样本个数），就不要转化为对偶问题求解了。
- 对偶问题是凸问题，相对容易求解。我们要知道对偶问题的解只是原问题的一个下界，只有当对偶间隙为0(强对偶)时，对偶问题的最优值才和原问题的最优值相等。

支持向量机的对偶问题

■ 优化问题

$$\min_{b, w} \frac{1}{2} \|w\|^2$$

$$s. t. \quad y_i(w^T \underline{x_i} + b) \geq 1$$

$$\text{或 } \phi(x_i), i = 1 \sim N$$

引入非线性变换时，特征维度 d 会很大，计算复杂度高

方案：把 $d+1$ 个变量、 n 个约束的优化问题转化为维度为 n 个变量、 $n+1$ 个约束的优化问题

举例：如果样本特征维度 d 是 100 万维，但样本数量 N 比较小，1000 个。原问题要解 100 万个变量，而对偶问题只需要解 1000 个变量 α 。

■ 支持向量机中引入对偶问题的优点

- 对偶问题容易求解
- 自然引入核函数



原问题与对偶问题

原问题

$$\min_{b, w} \frac{1}{2} \|w\|^2$$

$$s. t. \quad y_i(w^T x_i + b) \geq 1$$

$$i = 1, \dots, N$$

拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$

为每个约束条件引入拉格朗日乘子

$$\alpha = (\alpha_1, \alpha_2, \dots, \alpha_N)^T$$

KKT条件: $\alpha_i = 0$ 或者 $y_i(w^T x_i + b) - 1 = 0$

根据拉格朗日对偶性，原问题的对偶问题是极大极小问题：

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha)$$

求 $L(w, b, \alpha)$ 对 w 和 b 的极小，再对 α 求极大



(1) 求 $\min_{w,b} L(w, b, \alpha)$

将拉格朗日函数 $L(w, b, \alpha)$ 分别对 w, b 求偏导，令其等于0

$$\nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0$$

(x_i, y_i) 是样本

$$\nabla_b L(w, b, \alpha) = -\sum_{i=1}^N \alpha_i y_i = 0$$

得

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad \sum_{i=1}^N \alpha_i y_i = 0$$

推导过程

代入拉格朗日函数，可得

$$\begin{aligned} L(w, b, \alpha) &= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i \\ &= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \end{aligned}$$

$$\min_{w,b} L(w, b, \alpha) = -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$



(2) 求 $\min_{w,b} L(w, b, \alpha)$ 对 α 的极大, 即是对偶问题

$$\begin{aligned} \max_{\alpha} & -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \\ \text{s.t.} & \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

将求极大转换为求极小, 得到与之等价的对偶最优化问题

$$\begin{aligned} \min_{\alpha} & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} & \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

求解 α_i : 二次规划问题





- α_i 是拉格朗日乘子，对应训练样本 (x_i, y_i) .
- 根据KKT条件：对任意训练样本 (x_i, y_i) ，总有 $\alpha_i=0$ 或 $y_i(w^T x_i + b) = 1$
- 若 $\alpha_i=0$ ，则该样本将不会在目前函数与属于条件的求和中出现，即不会对判别有任何影响；
- 若 $\alpha_i > 0$ ，则必有 $y_i(w^T x_i + b) = 1$ ，所对应的样本点位于最大间隔边界上，是一个支持向量。
- 支持向量机的一个重要性质：训练完成后，大部分的训练样本都不需保留，最终模型仅与支持向量有关。





软间隔支持向量机的对偶问题

原问题:

$$\begin{aligned} \min_{b, \mathbf{w}, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(\|\mathbf{w}\|^2 + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, i = 1, \dots, n \end{aligned}$$

对偶问题:

$$\max_{\text{all } \alpha_i \geq 0, \beta_i \geq 0} \left(\min_{b, \mathbf{w}, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i + \sum_{i=1}^n \alpha_i (1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b)) + \sum_{i=1}^n \beta_i (-\xi_i) \right)$$

把和 ξ_i 有关的项整理在一起:

$$\max_{\text{all } \alpha_i \geq 0, \beta_i \geq 0} \left(\min_{b, \mathbf{w}, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) + \sum_{i=1}^n (C - \alpha_i - \beta_i) \xi_i \right)$$

令 $\mathcal{L}$ 对 ξ_i 的偏导为 0, 可得 $\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \alpha_i - \beta_i = 0$, 代入上式:

$$\max_{\text{all } 0 \leq \alpha_i \leq C} \left(\min_{b, \mathbf{w}} \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)) \right)$$





软间隔支持向量机的对偶问题

优化目标：

$$\max_{\text{all } 0 \leq \alpha_i \leq C} \left(\min_{b, \mathbf{w}} \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) \right)$$

令 $\mathcal{L}(b, \mathbf{w}, \alpha)$ 对 $\mathbf{w}$ 和 b 的偏导为 0，可得

$$\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \alpha_i y_i = 0$$

代入优化目标，可得

$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^n \alpha_i$$

可引入内积由核函数替代
 $K(x_1, x_2) = \phi^T(x_1) \phi(x_2)$

$$\text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, n$$



核函数支持向量机的对偶问题

- 用核函数 $K(x_i, x_j) = \phi^T(x_i)\phi(x_j)$ 代替对偶问题目标函数中的内积 $x_i \cdot x_j$:

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

- 分类函数中的内积也用核函数代替，决策函数为:

$$\begin{aligned} f(x) &= \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i \phi(x_i) \cdot \phi(x) + b_i\right) \\ &= \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b_i\right) \end{aligned}$$

将原来输入空间变换到一个新的特征空间，在新的特征空间里训练样本中学习线性支持向量机。



■ 线性可分支持向量机器学习算法

(1) 给定线性可分的数据集，首先求解出对偶问题的解 α^*

(2) 计算

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

选一个符合约束条件的 α_j^* 计算 $b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$

得到原问题的解 w^* 和 b^*

(3) 得到分离超平面和分类决策函数





■ 线性支持向量机器学习算法

(1) 选择惩罚参数 $C > 0$ ，求解对偶问题的解 α^*

(2) 计算
$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

选一个符合约束条件的 α_j^* 计算
$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

得到原问题的解 w^* 和 b^*

(3) 得到分离超平面和分类决策函数



■ 非线性支持向量机学习算法

- (1) 选取适当的核函数 $K(x_1, x_2)$ 和适当的 C ，求解对偶问题的解 α^*
- (2) 选一个符合约束条件的 α_j^* 计算

$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

- (3) 得到分类决策函数：
$$f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b_i\right)$$



求解 α_i 的方法

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

可引入内积由核函数替代
 $K(x_1, x_2) = \phi^T(x_1)\phi(x_2)$

$$s. t. \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, N$$

求解 α_i ：二次规划问题

- 凸二次优化问题具有全局最优解
- 样本容量较大时，非常低效
- 如何高效实现SVM的学习？



■ 1998年Platt提出启发式SMO算法，求解对偶问题

- 变量为拉格朗日乘子，一个变量 α_i 对应一个样本 (x_i, y_i)
- 在每次迭代中，**选择两个 α 值**（**违反KKT条件**最多的一对）进行优化，其余参数都视为常数，从而问题就变成了类似于**二次方程求**最大值的问题

对已有的模型来说，及其对应样本的 KKT 条件为：

$$\begin{aligned} \alpha_i = 0 &\Leftrightarrow y_i f(x_i) > 1 & \cdot & \alpha_i = 0 \Leftrightarrow \text{样本离间隔超平面比较远} \\ 0 < \alpha_i < C &\Leftrightarrow y_i f(x_i) = 1 & \cdot & 0 < \alpha_i < C \Leftrightarrow \text{样本落在间隔超平面上} \\ \alpha_i = C &\Leftrightarrow y_i f(x_i) < 1 & \cdot & \underline{\alpha_i = C} \Leftrightarrow \text{样本在间隔超平面以内} \quad \text{违反KKT条件} \end{aligned}$$

违反KKT条件的理解：

- 对于 $\alpha_i = 0$ 的点：它们是“非支持向量”。按照理论，它们应该离决策边界足够远（距离 ≥ 1 ）。如果 $y_i f(x_i) < 1$ ，说明这个点居然跑到了间隔边界内部，甚至被分错了，那它的 α_i 就不该是 0，必须增大来纠正。
- 对于 $0 < \alpha_i < C$ 的点：它们是“黄金支持向量”，必须严格落在 $y_i f(x_i) = 1$ 的边界线上。如果它偏离了，说明模型还没对齐。
- 对于 $\alpha_i = C$ 的点：它们是“受难点”，可能在间隔内或者被分错了。只要它们在边界内（ $y_i f(x_i) \leq 1$ ）就是正常的。但如果 $y_i f(x_i) > 1$ ，说明这个点明明已经分对了且离边界很远， α_i 却依然等于最大惩罚值 C ，这显然浪费了“精力”，需要调小。

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s. t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

在 SMO 每次迭代时，我们固定了除了 α_1, α_2 之外的所有变量。此时，原始的对偶问题目标函数（那一串复杂的求和）可以简化为一个只包含 α_1, α_2 的二次多项式：

$$W(\alpha_1, \alpha_2) = A\alpha_1^2 + B\alpha_2^2 + C\alpha_1\alpha_2 + D\alpha_1 + E\alpha_2 + \text{常数}$$

同时，它们必须满足线性约束： $\alpha_1 y_1 + \alpha_2 y_2 = \zeta$ 。

我们利用这个约束把 α_1 用 α_2 表示出来，代入目标函数，它就变成了一个关于 α_2 的开口向上的抛物线。对这个抛物线求导并令其为零，解出来的结果就是你看到的这个公式。

选择 α_2 的本质是**“找最极端的差生”**。 E_1 代表了一个犯错严重的样本，我们要在剩下的样本里找一个“犯错方向最不一样”的 E_2 配合它，通过两者的对调和补偿，最快地纠正模型的偏差。

求出“未裁剪” 的解析解

通过求导并令其为零，我们可以直接得到 α_2 的新值：

$$\alpha_2^{new,unt} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$

其中：

- E_i 是模型对第 i 个样本的预测误差。
- η 是关于核函数的二阶导数信息 ($\eta = K_{11} + K_{22} - 2K_{12}$) 。

裁剪与更新

虽然我们算出了一个解析解，但别忘了 α 还有范围约束： $0 \leq \alpha_i \leq C$ 。
加上之前的线性约束 $\alpha_1 y_1 + \alpha_2 y_2 = \zeta$ ，这在二维平面上表现为一条线段。

我们需要根据这条线段的上下界 (L 和 H)，对 $\alpha_2^{new,unt}$ 进行“裁剪”：

- 如果算出来的 $\alpha_2 > H$ ，就让它等于 H ；
- 如果 $\alpha_2 < L$ ，就让它等于 L 。

最后，根据 α_2 的变化量，反推回 α_1 的变化量。



1. 初始化拉格朗日乘子：首先，将拉格朗日乘子（ α 值）初始化为零或某些小的随机值。
2. 选择两个 α 值：在算法的每次迭代中，选择两个 α 值进行优化。选择是基于一个称为**最大违反对的启发式方法**，该方法**选择违反KKT条件最多的一对**。
3. 优化选择的 α 值：然后，根据优化问题的约束条件，优化所选的 α 值。这是通过使用一组解析公式来完成的，这些公式允许高效地进行优化。
4. 更新阈值：在每次迭代后，根据更新后的 α 值重新计算阈值。
5. 选择下一个 α 值对：然后，选择下一对 α 值对进行优化，并重复2-4步骤，直到收敛为止。

SMO算法通过将优化问题分解为一系列较小的优化问题来解决SVM的优化问题，每个子问题只涉及两个 α 值。由于SMO算法的高效性和易于实现性，它已成为SVM中最受欢迎的训练算法之一。



- 正例点: $x_1 = (3,3)^T, y_1 = 1; x_2 = (4,3)^T, y_2 = 1$,
- 负例点: $x_3 = (1,1)^T, y_3 = -1$
- 解: 对偶形式

$$\begin{aligned}
 \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\
 & \xrightarrow{\quad} \boxed{1 * 1 * (3 \quad 3) \begin{pmatrix} 3 \\ 3 \end{pmatrix}} \\
 & = \frac{1}{2} (18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) - \alpha_1 - \alpha_2 - \alpha_3 \\
 \text{s.t.} \quad & \alpha_1 + \alpha_2 - \alpha_3 = 0 \quad \leftarrow \boxed{\sum_{i=1}^n \alpha_i y_i = 0} \\
 & \alpha_i \geq 0, \quad i=1,2,3
 \end{aligned}$$

- 将 $\alpha_3 = \alpha_1 + \alpha_2$, 带入目标函数并记为

$$s(\alpha_1, \alpha_2) = 4\alpha_1^2 + \frac{13}{2}\alpha_2^2 + 10\alpha_1\alpha_2 - 2\alpha_1 - 2\alpha_2$$



- 对 α_1, α_2 求偏导数，并令其为0，易知 $s(\alpha_1, \alpha_2)$ 在 $\left(\frac{3}{2}, -1\right)^T$ 取极值，但该点不满足约束条件 $\alpha_2 \geq 0$ ，所以最小值应在边界上达到
- 当 $\alpha_1 = 0$ 时，最小值 $s\left(0, \frac{2}{13}\right) = -\frac{2}{13}$
- 当 $\alpha_2 = 0$ 时，最小值 $s\left(\frac{1}{4}, 0\right) = -\frac{1}{4}$
- 于是 $s(\alpha_1, \alpha_2)$ $\alpha_1 = \frac{1}{4}, \alpha_2 = 0$ 获得极小， $\alpha_3 = \alpha_1 + \alpha_2 = \frac{1}{4}$
- 这样 $\alpha_1^* = \alpha_3^* = \frac{1}{4}$ 对应的实例向量为支持向量





■ 计算: $\alpha_1, \alpha_2, \alpha_3$ 带入 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$ 得到 $w_1^* = w_2^* = \frac{1}{2}$

$$b^* = y_i - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad b^* = -2$$


■ 分离超平面为: $\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$

■ 分类决策函数为: $f(x) = \text{sign}\left(\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2\right)$





- 支持向量机由简至繁的模型：
 - 线性可分支持向量机----间隔最大
 - 线性支持向量机----软间隔
 - 非线性支持向量机----核函数



- SVM 的基本思想是，通过寻找最优的“**分离超平面**” (separating hyperplane)，将两类数据分离开。
- SVM 特别适用于变量很多的数据，因为在高维空间，数据被“打散”，故更容易用超平面进行分离。
- SVM 在变量较多的数据中有很多成功的应用，比如文本分析与图像识别。例如，SVM 曾在手写数字识别的 MNIST 数据集取得巨大成功。

请建立一个非线性数据集，并且用SVM进行分类



这里是一个使用Python和Scikit-learn库生成非线性数据集并用SVM进行分类的例子。我们将生成一个包含两个类别的非线性数据集，并使用RBF核函数的SVM对数据进行分类。

```
python
import numpy as np
import matplotlib.pyplot as plt
from sklearn import datasets
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC

# 生成非线性数据集
X, y = datasets.make_moons(n_samples=200, noise=0.15, random_state=42)

# 将数据集分为训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 数据预处理：标准化
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
```



- SVM与逻辑回归的区别
- SVM与Fisher判别法的区别